Tamizaje automatizado de glaucoma con Inteligencia Artificial

Bonilla, J. S., Cobaleda, J., Gómez, E., Méndez, L. M.
johan.bonilla@u.icesi.edu.co , josue.cobaleda@u.icesi.edu.co ,
edwin.gomez@u.icesi.edu.co lina.mendez@u.icesi.edu.co

Tutor: Milton Orlando Sarria Paja

Enlace del video:
https://drive.google.com/file/d/1NnGeQnpbsf_Qs9H8tZIJIR5P_awR4sah/view

Enlace del GitHub:
https://github.com/edgo1688/MIAA-ICESI-ProyectoIA

El glaucoma es una de las principales causas de ceguera irreversible a nivel mundial. El proyecto desarrolla un sistema automatizado de tamizaje basado en aprendizaje profundo para detectar glaucomas en fotografías de fondo de ojo. Se integraron tres bases públicas (ORIGA, G1020, REFUGE) que reúnen más de 2 000 imágenes procedentes de Asia, Europa y Sudamérica. Tras la limpieza, estandarización y aumento de datos, se entrenaron modelos de transferencia de aprendizaje (VGG16, Inception, ResNet50, Xception) y un modelo final optimizado con validación cruzada estratificada. El enfoque prioriza la sensibilidad (≥ 85 %) y especificidad (≥ 80 %) para cada predicción. Los resultados preliminares muestran unas cifras esperanzadoras, demuestra el potencial de aplicar IA para la detección temprana de glaucoma y sienta las bases para validar el modelo en poblaciones latinoamericanas.

Índice de Términos: *Glaucoma, detección temprana, inteligencia artificial, imágenes de fondo de ojo, deep learning.*

I. INTRODUCCIÓN

El glaucoma es una neuropatía óptica crónica que afecta a más de 76 millones de personas y se proyecta que superará los 110 millones en 2040. Su detección temprana es crítica, pero los métodos convencionales requieren equipos costosos y especialistas escasos, lo que restringe el tamizaje masivo, especialmente en regiones de bajos recursos. Los avances recientes en visión por computador y aprendizaje profundo han mostrado altos niveles de precisión en la interpretación de retinografías. Este proyecto aborda el desafío de crear un sistema globalmente robusto, explicable y eficiente que identifique con rapidez ojos glaucomatosos a partir de imágenes de fondo de ojo, con la idea de a futuro aplicar estos modelos para poblaciones latinoamericanas.

Planteamiento del problema

El glaucoma es una neuropatía óptica crónica y una de las principales causas de ceguera irreversible a nivel mundial. Se estima que afecta a más de 76 millones de personas para 2020, con proyecciones que superan los 110 millones en 2040 [1]. Este impacto conlleva costos económicos sustanciales: por ejemplo, en EE.UU. el tratamiento de ≈2 millones de pacientes con glaucoma implica costos directos anuales de ≈$2.9 mil millones [2]. Gran parte de esta pérdida de visión es evitable mediante diagnóstico y tratamiento oportunos; sin embargo, el tamizaje masivo de glaucoma presenta varios desafíos. Existe escasez de oftalmólogos para cubrir a poblaciones envejecidas y rurales, y las evaluaciones clínicas son lentas y subjetivas. La detección tradicional requiere exámenes especializados (ej. tonometría, campimetría visual) y equipos costosos como OCT (tomografía de coherencia óptica), poco viables para despistajes poblacionales extensivos por su tiempo y costo.

Además, hay variabilidad diagnóstica incluso entre expertos, especialmente en etapas tempranas donde los hallazgos (como la relación copa/disco) pueden ser sutiles [3].

El problema central es cómo realizar un tamizaje automatizado, rápido y preciso del glaucoma usando imágenes de fondo de ojo, superando las limitaciones actuales. Los stakeholders clave incluyen: pacientes (quienes se benefician de la detección precoz para prevenir la ceguera), aseguradoras/EPS (que buscan reducir costos de tratamientos tardíos), hospitales y clínicas (que podrían agilizar flujos de trabajo de oftalmología), startups y fabricantes de dispositivos (desarrollando cámaras portátiles y software de IA para detección ocular), y entes reguladores (FDA, EMA, Invima) que exigen eficacia y seguridad antes de aprobar estas herramientas.

Desde la perspectiva del negocio, se han definido restricciones y criterios de éxito mínimos: la herramienta de IA debe alcanzar una precisión clínica aceptable, típicamente sensibilidad ≥ 0.85 y especificidad ≥ 0.80 (umbral mínimo recomendado para tamizaje poblacional) [4]. Es fundamental la explicabilidad del modelo – es decir, que provea salidas interpretables (ej. mapa de calor sobre el disco óptico) para generar confianza en médicos y cumplir requerimientos regulatorios. Se deben mitigar riesgos éticos, como sesgos que disminuyan rendimiento en ciertos grupos (p. ej., sobre diagnóstico en etnias específicas) o fallos de privacidad (asegurando anonimización de las imágenes). Además, el sistema debe ser eficiente: inferencia en <1 segundo por imagen y costo por examen <USD $1, para que el tamizaje a gran escala sea viable en entornos de bajos recursos.

El enfoque del proyecto es global en lugar de regional: el modelo se entrenará con miras a aplicarse en diversas poblaciones y países, ya que se contará con bases de datos de diferentes latitudes. Esto conlleva retos de generalización: las características demográficas (edad, raza) influyen en la apariencia del fondo de ojo (por ejemplo, diferencias en pigmentación retiniana o tamaño del disco óptico por etnia). Asimismo, existe variabilidad técnica entre dispositivos – distintas cámaras retinianas producen resoluciones y campos de visión heterogéneos. Un algoritmo global debe manejar estos sesgos y variaciones, evitando un desempeño inferior en ciertas regiones. En suma, el problema requiere una solución de IA robusta, explicable y equitativa para el tamizaje universal de glaucoma, optimizando la detección temprana y aliviando la carga asistencial.

Se identifican a continuación, mediante la gráfica de un árbol de problemas, respectivamente y de izquierda a derecha: las causas, el problema principal a abordar y las consecuencias del mismo.

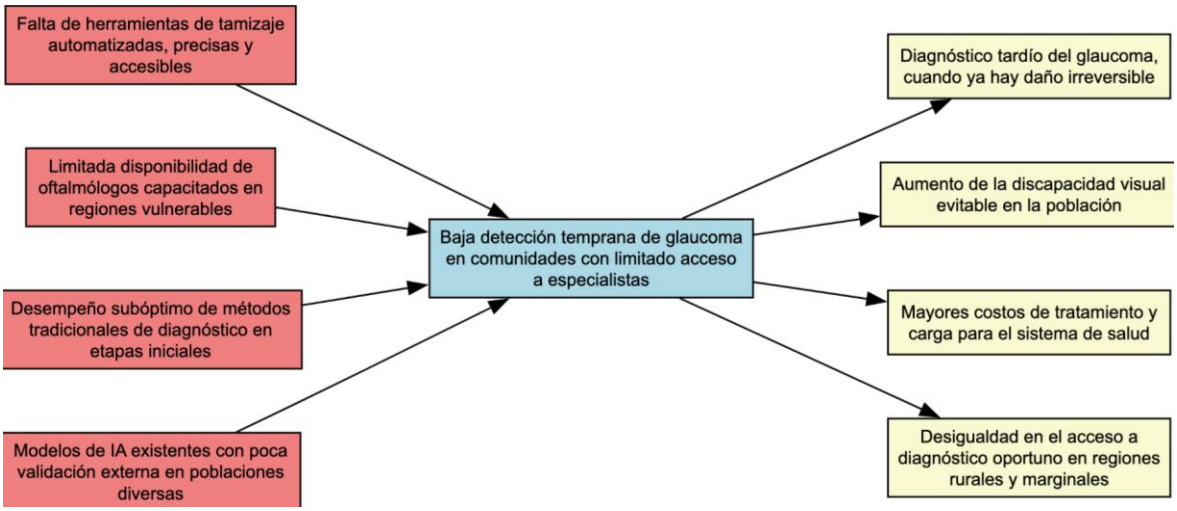


Fig. 1. Árbol de problemas sobre la baja detección temprana de glaucoma en comunidades con limitado acceso a especialistas.

Objetivos

Usando la metodología de objetivos SMART se plantea el siguiente objetivo:

Desarrollar e implementar, para junio de 2025, un sistema automatizado de detección de glaucoma a partir de fotografías de fondo de ojo. El modelo deberá identificar ojos glaucomatosos con al menos un 85% de sensibilidad y un 80% de especificidad, de acuerdo con su desempeño en un conjunto de prueba multicéntrico internacional. Para alcanzar esta meta, se empleará un modelo de deep learning optimizado que justifique cada predicción de manera interpretable. Este objetivo es clínicamente relevante, ya que una herramienta de tamizaje precisa y rápida puede ampliar la detección temprana del glaucoma en comunidades con escasez de especialistas.

De este objetivo se derivan:

- Diseñar y entrenar un modelo de deep learning basado en imágenes de fondo de ojo, optimizado para identificar ojos glaucomatosos con alta sensibilidad y especificidad, utilizando un conjunto de datos internacional.

- Validar el desempeño del modelo en un conjunto de prueba.

- A futuro, realizar una evaluación externa del modelo en imágenes de pacientes latinoamericanos (ej., en Colombia) con el fin de identificar posibles sesgos y ajustar el sistema para su aplicabilidad regional.

Contexto: Revisión de la literatura y hallazgos clave de estudios recientes (2019–2025).

La aplicación de inteligencia artificial al diagnóstico de glaucoma ha avanzado notablemente en los últimos años (Li et al., 2024). Diversos enfoques han sido investigados, desde algoritmos de aprendizaje profundo hasta técnicas clásicas de visión por computador. Por ejemplo, López-Gálvez et al. (2023) exploraron un **método tradicional basado en análisis de texturas para detectar lesiones retinianas** [5]. Empleando segmentación semiautomática y verificación de regiones, lograron identificar exudados duros en imágenes de fondo de ojo con sensibilidad 0.92–0.98 y especificidad 0.90–0.98 en varios conjuntos de datos. Si bien este estudio se enfoca en retinopatía diabética (no en glaucoma), ilustra que las técnicas de procesamiento de imagen bien diseñadas (filtro de mediana, detección de bordes, eliminación del disco óptico, etc.) pueden alcanzar alta precisión sin redes neuronales profundas.

En contraste, **los métodos basados en deep learning dominan la literatura reciente de glaucoma**. Díaz-Pinto et al. (2019) [6] emplearon cinco arquitecturas de red neuronal convolucional (CNN) pre-entrenadas (VGG16, InceptionV3, ResNet50, Xception, etc.) para clasificación binaria glaucoma/normal en 5 bases de datos públicas (N=1707 imágenes). Obtuvieron resultados sobresalientes: el mejor modelo (Xception) rindió con un área bajo la curva AUC ≈0.96, sensibilidad ≈0.93 y especificidad ≈0.86 promediadas. Además, liberaron una nueva base de 705 imágenes (ACRIMA) con 396 casos de glaucoma, ampliando el mayor conjunto público disponible. Este trabajo confirmó que la transferencia de aprendizaje desde ImageNet proporciona representaciones robustas en retina, superando enfoques previos con extracción manual de características. De hecho, métodos tradicionales como SVM con descriptores HOG o transformadas wavelet lograban desempeños moderados (ej., accuracies ≈80%), mientras que las CNN aprendieron directamente patrones sutiles del nervio óptico con mayor discriminación.

Un **desafío común identificado es la generalización multisitio**. Modelos entrenados en un único centro a menudo ven mermado su desempeño al probarse en datos externos debido a shift de distribución (diferentes poblaciones, prevalencias y dispositivos). Hemelings et al. (2023) [7] abordaron este problema integrando 13 fuentes de datos de todo el mundo, incluyendo dos cohortes poblacionales grandes (Blue Mountains Eye Study en Australia y Gutenberg Health Study en Alemania) junto con 11 datasets públicos de glaucoma. Estandarizaron todas las imágenes a un campo de 30° centrado en el disco óptico para reducir variaciones técnicas. Entrenaron un modelo de regresión (G-RISK) para estimar la probabilidad de glaucoma (en lugar de solo clasificación binaria), logrando desempeños impresionantes en detección de casos referibles: AUC = 0.976 y 0.984 en las cohortes de población, con sensibilidades ≈87–90% a especificidad fija de 95%. En 11 conjuntos externos adicionales, el AUC osciló entre 0.85 y 0.99, confirmando la robustez del modelo en entornos

desafiantes. Este estudio destaca la importancia de datasets diversos y de preprocesamiento consistente (alinear imágenes al disco) para un enfoque global.

De manera complementaria, Li et al. (2022) [8] desarrollaron un **sistema de deep learning capaz de predecir tanto la incidencia de glaucoma en pacientes inicialmente sanos, como la progresión en pacientes ya diagnosticados**, a partir de fotografías de retina. Entrenado con miles de imágenes de múltiples centros en China, su algoritmo alcanzó AUROC ≈0.90 en la predicción a 4 años de nuevos casos de glaucoma, manteniendo AUROC ≈0.88–0.89 en dos conjuntos de prueba externos. Para progresión de glaucoma (deterioro del campo visual), también logró alta exactitud. Un hallazgo importante es que el modelo no mostró diferencias significativas de rendimiento al estratificar por edad o sexo de los pacientes, lo cual sugiere que el algoritmo supo evitar ciertos sesgos demográficos y podría ser aplicado consistentemente en subpoblaciones diversas. Esto es crítico para la equidad del tamizaje.

La literatura reciente también ha explorado **arquitecturas novedosas y combinaciones de modalidades**. Sharma et al. (2025) [9] propusieron un enfoque híbrido multi-modelo llamado AI-GS, que integra 6 sub-modelos livianos enfocados en distintos biomarcadores de glaucoma (segmentación de la copa y disco óptico, detección de hemorragias discales, defectos de capa de fibras nerviosas, etc.). Cada sub-modelo (<20 MB) analiza la imagen de fondo de ojo para una característica específica; luego sus salidas se fusionan en una red plenamente conectada que estima la probabilidad final de glaucoma. En un set de prueba interno, AI-GS alcanzó sensibilidad = 93,5% a 95% de especificidad, superando claramente el umbral clínico. En pruebas de campo real (pacientes de clínica, con variabilidad no controlada), reportaron que un modelo CNN estándar sufría una caída de sensibilidad a ≈56% manteniendo ≈94% especificidad, mientras que la red completa AI-GS mantuvo ≈80.5% de sensibilidad con ≈91% especificidad. Esto demuestra que combinar múltiples detectores especializados mejora la sensibilidad en datos del mundo real, detectando cambios sutiles que un único clasificador podía pasar por alto. No obstante, también refleja la brecha que suele haber entre la evaluación controlada y el desempeño clínico real, subrayando la importancia de validar con datos prospectivos.

En otra línea, Díaz-Pinto et al. (2019) [6] y otros autores resaltan la **necesidad de imágenes de alta calidad para un diagnóstico fiable**. Imágenes borrosas o con mala iluminación pueden inducir errores; por ello, se han propuesto modelos auxiliares que filtren automáticamente imágenes no aptas. Por ejemplo, una red de clasificación de calidad puede descartar fotos desenfocadas antes del análisis principal (Ran et al., 2022) [10]. Asimismo, varios trabajos incorporan medidas clínicas explícitas: segmentar el disco y la copa óptica para calcular la relación copa/disco (CDR) e incluirla como característica en la decisión. Este enfoque híbrido combina la naturaleza data-driven de las CNN con conocimiento clínico previo – CDR elevada es un indicador tradicional de glaucoma. Estudios han demostrado que agregar CDR u otros rasgos (excavación, hemorragias peripapilares) mejora la interpretabilidad e incluso la precisión del modelo (Shankaranarayana et al., 2020) [11].

En cuanto a plataformas emergentes, se investiga la aplicabilidad en dispositivos móviles: por ejemplo, algoritmos optimizados para ejecutarse en smartphones acoplados a lentes de bajo costo, lo que permitiría tamizajes en campo. Un ejemplo es el uso de Vision Transformers y métodos compactos en aplicaciones de tele-oftalmología móvil (Li et al., 2024; Xu et al., 2023) [12], aunque aún es un área en desarrollo.

Mejores prácticas y vacíos identificados.

De la revisión de estos artículos se desprenden varias recomendaciones técnicas relevantes para nuestro proyecto. Primero, el ****manejo de la clase minoritaria (ojos glaucomatosos) es crucial****: en poblaciones generales la prevalencia de glaucoma puede ser <5%, de modo que entrenar un modelo sin técnicas de balanceo puede sesgarlo a predecir "sano" la mayoría de veces. Los investigadores han utilizado enfoques de oversampling (replicar o sintetizar imágenes de glaucoma) y cost-sensitive learning (ponderar más los errores en glaucomatosos). Por ejemplo, algunos grupos aplicaron focal loss o ajustaron manualmente el peso de falsos negativos para priorizar la sensibilidad (Li et al., 2024) [12]. Esto coincide con la prioridad clínica de minimizar falsos negativos – es preferible marcar un caso como sospechoso (aunque luego se descarte con exámenes confirmatorios) que perder un glaucoma real por no detectarlo. Segundo, se ha validado la ****utilidad del transfer learning****: la mayoría de estudios (Díaz-Pinto 2019, Hemelings 2023, etc.) iniciaron entrenando sus

CNN con pesos de ImageNet, dado el limitado tamaño de datasets médicos. Esto aceleró la convergencia y permitió que modelos complejos rindieran bien con cientos o pocos miles de imágenes. Tercero, las ****técnicas de data augmentation se consideran indispensables****. Todos los trabajos analizados aplicaron transformaciones aleatorias a las imágenes de entrenamiento (giros, espejado horizontal, variaciones de brillo/contraste). Algunas publicaciones implementaron augmentations más sofisticadas: deformaciones elásticas simulando distorsiones oculares, recortes aleatorios centrados en el nervio, e incluso redes generativas (GANs) para crear imágenes sintéticas de discos excavados. López-Gálvez et al. (2023) [5] mencionan que su método clásico evitó depender de equalización de iluminación o segmentación vascular previa, lo que simplifica la generalización; sin embargo, en modelos de deep learning sí se sugiere normalizar la coloración y eliminar artefactos (reflejos) en pre-procesamiento para reducir la variabilidad no informativa.

Otro aspecto crítico es la **interpretabilidad**. Dado que las autoridades regulatorias ahora exigen justificar las decisiones de los algoritmos médicos, muchos estudios integran métodos de explicación. Los más comunes son Grad-CAM (mapas de activación vinculados a la predicción) y LIME, que señalan regiones del fondo de ojo que contribuyen al diagnóstico (usualmente el área del disco óptico y la capa de fibras nerviosas). Por ejemplo, Li et al. (2024) [8] en su revisión enfatizan que la transparencia es clave para la adopción clínica, y proponen que un enfoque ideal podría involucrar un sistema híbrido, donde la IA no solo indique "glaucoma: sí/no" sino que provea medidas cuantitativas tradicionales (como CDR) y visualizaciones comprensibles (p. ej., destacar una hemorragia discal detectada).

Finalmente, permanecen vacíos importantes en la literatura. Pocos trabajos han validado sus algoritmos en población latinoamericana o africana, representando una brecha de equidad. Asimismo, la mayoría de estudios utilizan solo imágenes de fondo de ojo estáticas; integrar datos multimodales (OCT, campos visuales, presión intraocular) podría mejorar la sensibilidad en casos tempranos donde la foto de retina por sí sola es insuficiente . También se señala que la heterogeneidad de criterios diagnósticos complica la comparación entre modelos – distintos datasets usan definiciones de glaucoma diferentes (p. ej., basado en CDR vs. basado en campos visuales). Esto sugiere la necesidad de estándares unificados y quizá entrenar modelos para estudiar severidad y no solo detección binaria.

En resumen, las investigaciones de 2019-2025 demuestran que la IA puede lograr desempeño cercano (incluso superior) al de especialistas en la detección de glaucoma (sensibilidades típicamente 90%+) [13], pero para trasladar esta eficacia a escenarios globales reales deben atenderse la generalización, interpretabilidad y sesgos, orientando así la propuesta de nuestro proyecto.

En función de lo revisado, identificamos áreas donde este proyecto puede aportar valor en un futuro cuando esté más maduro:

- Validación en Latinoamérica: Actualmente falta evidencia de desempeño de algoritmos de glaucoma en poblaciones latinoamericanas. Nuestro proyecto puede liderar estudios de validación externa en Colombia, probando la herramienta en etnias y condiciones locales poco representadas, y ajustando el modelo para cubrir esas diferencias (p. ej., prevalencia de pseudoexfoliación, características genéticas particulares). Esto aumentará la confianza de adoptabilidad regional.

- Mejora en interpretabilidad y confianza del usuario: Aunque muchos estudios mencionan Grad-CAM, pocos han evaluado sistemáticamente cómo usan los clínicos esas explicaciones. El proyecto puede innovar presentando las salidas de IA de forma intuitiva y validándolas con oftalmólogos en un entorno simulado. Esto cerraría la brecha entre un algoritmo con buen desempeño y su aceptación en práctica real, ofreciendo un ejemplo de IA explicable centrada en el usuario.

El alcance de este proyecto se limitará a probar en primera instancia los modelos que pueden ayudar a detectar glaucoma para ello se utilizaron los siguientes materiales y métodos.

II. MATERIALES Y MÉTODOS

2.1 Marco teórico y enfoque metodológico

El proyecto se apoya en las redes convolucionales profundas (CNN) pre-entrenadaS. Esta estrategia permite reutilizar filtros visuales genéricos y ajustarlos a la anatomía ocular, reduciendo el riesgo de overfitting cuando los datos médicos son limitados. Dados los requisitos clínicos de un tamizaje (sensibilidad ≥ 85 %, especificidad ≥ 80 %), se buscará obtener el mejor resultado posible. El flujo general comprende: (i) integración y estandarización multibase, (ii) preprocesamiento y aumento de datos dirigidos, (iii) entrenamiento y fine-tuning de cuatro CNN de referencia, (iv) validación cruzada estratificada y (v) análisis de interpretabilidad y umbral operativo.

2.2 Hardware y software

Recurso	Detalle
Lenguaje/Entorno	Python 3.11, Jupyter Lab
Frameworks	TensorFlow 2.16.2 (Keras API), scikit-learn 1.4, OpenCV-Python 4.9
Librerías auxiliares	imbalanced-learn 0.12, matplotlib 3.9, pandas, NumPy.
Hardware	Google Colab (Tesla T4 16 GB)
Control de versiones	Git y GitHub

Conjuntos de datos

El proyecto se apoya en tres bases públicas y complementarias, seleccionadas por su calidad de anotación y su diversidad étnica y técnica:

1. ORIGA(-light) contiene 650 imágenes retinianas anotadas por profesionales formados del Instituto de Investigación Ocular de Singapur y ofrece fotografías de 30° capturadas con cámara Canon CR-1 (2 048 × 1 536 px). La base de datos está compuesta por un conjunto de imágenes y un archivo en formato CSV que contiene las columnas que se aprecian a continuación: las columnas (Image, CDR, Ecc-Cup, Ecc-Disc) corresponden a variables explicativas y la última (Glaucoma) corresponde a nuestra variable clasificatoria. Cada una de estas columnas se explica de la siguiente manera:

- Image: Nombre de archivo de imagen.
- Source: Fuente del dato
- CDR: Cup-to-Disc Ratio. Proporción entre el diámetro del "cup" (excavación central) y el disco óptico. Valor clave en la detección de glaucoma..
- Ecc-Cup: Excentricidad de la región de excavación del nervio óptico (cup). Una medida morfológica.
- Ecc-Disc: Excentricidad del disco óptico completo. Ayuda a describir la forma del disco.
- Glaucoma: Variable clasificatoria que identifica el diagnóstico negativo (0) o positivo (1) del glaucoma.

Enlace de la base de datos ORIGA: https://ieeexplore.ieee.org/document/5626137

2. G1020: Esta base de datos consta de 1020 imágenes de fondo de ojo en color de alta resolución y proporciona anotaciones de la verdad fundamental para el diagnóstico del glaucoma. Compila retinografías de alta resolución (hasta 4 992 × 3 328 px) provenientes de clínicas españolas y brasileñas, con anotación experta del diagnóstico final (Glaucoma 0/1). Aunque no aporta máscaras ni métricas morfológicas, destaca por su tamaño intermedio y por la heterogeneidad de cámaras (Topcon, Canon) y poblaciones, lo que ayuda a evaluar la capacidad de generalización del algoritmo. La base de datos está compuesta por un conjunto de imágenes y un archivo en formato CSV en donde se encuentra el label de la variable predictora (Glaucoma)
Enlace de la base de datos G1020: https://paperswithcode.com/paper/g1020-a-benchmark-retinal-fundus-image

3. REFUGE. Concebida para el Retinal Fundus Glaucoma Challenge 2019, comprende 400 fotos para entrenamiento, 400 de validación y 400 reservadas para prueba ciega; todas con campo de 45° y resolución

estándar 2 124 × 2 052 px. Incluye: (i) la etiqueta Glaucoma 0/1 verificada por consenso de tres oftalmólogos y (ii) máscaras pixeladas de disco y copa óptica, útiles para calcular CDR y generar mapas de calor de referencia. La cohorte mezcla pacientes chinos del Zhongshan Ophthalmic Center y europeos del MESSIDOR, aportando variabilidad étnica y de dispositivos. Enlace de la base de datos REFUGE: https://www.sciencedirect.com/science/article/abs/pii/S1361841519301100?via%3Dihub

4. Una cuarta base que representa una cohorte de imágenes retinianas de pacientes de Cali se reserva para validación externa en futuros alcances de este proyecto.

En conjunto, disponemos de más de dos mil imágenes con aproximadamente 23 % de casos glaucomatosos. Las imágenes cubren tres continentes (Asia, Europa, Sudamérica) y abarcan campos de 30° – 45°, resoluciones de 1.5 MP a 5 MP y distintos fabricantes de cámaras; esta heterogeneidad permitirá evaluar de forma realista la robustez de los modelos a probar.

2.4 Preprocesamiento y preparación de datos

1. **Verificación y limpieza:** Se utilizaron tres bases de datos compuestas por imágenes de retina anotadas con las etiquetas correspondientes a presencia o ausencia de glaucoma. A continuación, se detallan las bases utilizadas y la cantidad de muestras en cada una:

Source	Cantidad
G1020	1.020
ORIGA	650
REFUGE	400

Las bases de datos contienen el nombre de la imagen, la clasificación de Glaucoma e información adicional como la relación entre copa-disco, estas bases fueron unificadas y se les adiciono la ruta de la imagen y el identificador de la fuente tal como se presenta a continuación:

	Source	Path	Image	Glaucoma
0	ORIGA	ORIGA\Images_Cropped\001.jpg	001.jpg	0
1	ORIGA	ORIGA\Images_Cropped\002.jpg	002.jpg	0
2	ORIGA	ORIGA\Images_Cropped\003.jpg	003.jpg	0
3	ORIGA	ORIGA\Images_Cropped\004.jpg	004.jpg	0
4	ORIGA	ORIGA\Images_Cropped\005.jpg	005.jpg	0

2. **Redimensionado:**
   - 224×224 px para VGG16;
   - 299×299 px para Inception V3 y Xception;
   - 350×350 px Region de interés (ROI) centrado en el nervio óptico para ResNet50, recortado con máscara circular para reducir ruido periférico ResNet50.

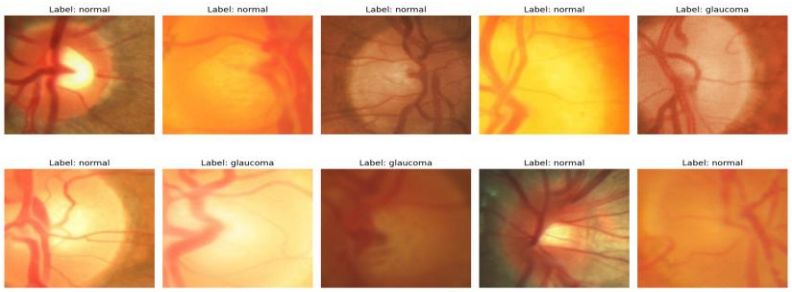


Figura 1. *Resultado de imágenes recortadas en el preprocesamiento para ResNet50*

3. **Normalización de intensidad:** *rescale = 1/255* más *preprocess_input* específico de cada arquitectura.
4. **Aumento y balanceo:** Durante el análisis exploratorio se identificó un desbalance en las clases, donde aproximadamente el 25 % de las muestras correspondían a casos positivos de glaucoma. Este desequilibrio representa un reto importante, ya que podría afectar la capacidad del modelo para generalizar correctamente. Para mitigar este problema, se aplicaron técnicas de aumento de datos dirigidas específicamente a la clase minoritaria. Estas incluyeron transformaciones como rotaciones, cambios de orientación y escalado de imágenes, con el objetivo de incrementar el número de muestras positivas hasta alcanzar un equilibrio entre las clases. Además del balanceo, se utilizaron transformaciones aleatorias sobre todas las clases para generar nuevas imágenes sintéticas. Estas transformaciones, rotaciones, cambios de orientación y escalados, se aplicaron con el fin de incrementar la diversidad del conjunto de entrenamiento y mejorar la capacidad del modelo para generalizar ante variaciones en los datos reales. En resumen: rotaciones ±15°, volteo horizontal, *zoom* y *shift* 10 %; sobre-muestreo 1:1 de la clase minoritaria y uso de `class_weight` para penalizar falsos negativos .

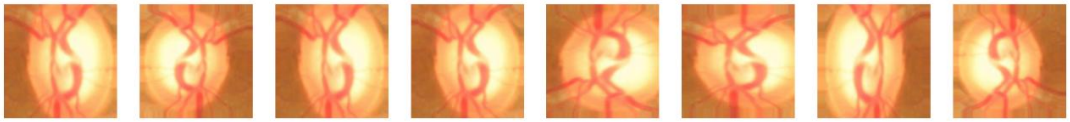


Figura 2. *Generación de 8 imágenes a partir de la misma muestra*

5. **División estratificada:** 80 % entrenamiento / 20 % validación para fases exploratorias; posteriormente validación cruzada estratificada k = 5 sobre el conjunto multicéntrico.

2.5 Modelos y procedimientos de entrenamiento

Modelo	Descripción corta
VGG16	Una arquitectura profunda, con 16 capas que se conectan secuencialmente.
Inception V3	Una red con múltiples caminos paralelos, capaz de analizar detalles a distintas escalas, al mismo tiempo.
ResNet50	Red con 50 capas y conexiones residuales que facilitan el aprendizaje en redes muy profundas.
Xception	Arquitectura basada en convoluciones separables en profundidad, que mejora la eficiencia y precisión.

1. Implementación del Modelo VGG16.
Para la detección de glaucoma, primero se utilizó el modelo VGG16 preentrenado en el conjunto de datos ImageNet, aprovechando su capacidad para extraer características visuales complejas. La arquitectura fue adaptada mediante los siguientes pasos:

- **Carga del modelo base:** Se cargó VGG16 excluyendo sus capas superiores (argumento include_top=False), manteniendo únicamente las capas convolucionales encargadas de la extracción de características. La entrada se configuró para aceptar imágenes RGB con forma (224, 224, 3).

- **Congelación de capas:** Se desactivó el entrenamiento de todas las capas convolucionales del modelo base para conservar los pesos preentrenados y evitar el sobreajuste en un conjunto de datos relativamente pequeño.

- **Añadir capas personalizadas:** Sobre la salida del modelo base se añadió una capa Flatten() para transformar los mapas de características en un vector unidimensional. A continuación, se añadió una capa densa con una única neurona y activación sigmoid para realizar la clasificación binaria (glaucoma/no glaucoma).

- **Definición y compilación del modelo:** Se construyó el modelo completo con la entrada del modelo base y la salida personalizada. El modelo se compiló con el optimizador Adam (tasa de aprendizaje de 0.0001), función de pérdida binary_crossentropy y métricas de evaluación como precisión binaria, AUC, precisión y recall.

Arquitectura VGG16

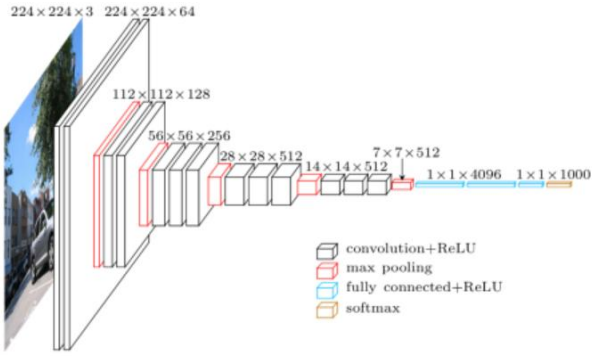


Figura 3. *Transformación en cada convolución para extraer información relevante*

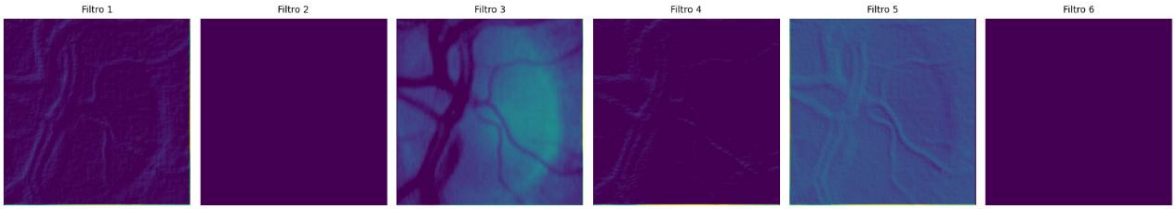


Figura 4. *Transformación en cada convolución para extraer información relevante*

2. **Implementación del Modelo InceptionV3**
En la carga del modelo InceptionV3, se utilizaron los datos pre-entrenados del dataset de ImageNet, el cual es un conjunto de datos de gran escala utilizado en clasificación de imágenes que ayuda al modelo a reconocer características visuales en las imágenes. Se excluyen las primeras capas del modelo original para utilizarlo sólo como un extractor de características y usar sólo las capas propias que fueron configuradas para el entrenamiento.

En modelos de aprendizaje por transferencia (transfer learning), como este, es también una práctica común realizar el congelamiento de los pesos del modelo base (modelo InceptionV3 pre-entrenado), para evitar problemas de sobreajuste (overfitting).

Haciendo uso de Keras y la base pre-entrenada de Imagenet, se utilizaron las siguientes capas como parte de la arquitectura del modelo:

- **Capa de entrada**: en la cual se define el tamaño y canales del dataset de imágenes.
- **Capa del modelo base InceptionV3:** con el congelamiento descrito previamente.
- **Capa de reducción de dimensiones:** usualmente utilizada con modelos pre-entrenados para reducir el número de parámetros (dimensiones en este caso) y evitar sobreajuste.
- **Capa de abandono (dropout)**: se utiliza igualmente para evitar sobreajuste, mediante la eliminación aleatoria de neuronas durante el entrenamiento. Favorece la generalización, dado que obliga al modelo a evaluar diferentes características cada vez.
- **Capa densa (256 unidades)**: capa completamente conectada que introduce no-linearidad mediante la función RELU, y que permite al modelo reconocer patrones complejos.
- **Capa de abandono (dropout)**: para regularización adicional.
- **Capa densa (con funsión sigmoide)**: para clasificación binaria (1 para indicar imagen con Glaucoma, 0 para indicar ojo sano).

Se utiliza el optimizador Adam para ajustar los pesos de la red neuronal durante el entrenamiento y las métricas de precisión (accuracy) y área bajo la curva (AUC) para medir el rendimiento del modelo.

Para entrenamiento del modelo se utilizaron 16 épocas y se definieron pesos para las clases, dado el desbalance que se indicó previamente. En este caso se fijó un peso de 0.66 para la clase mayoritaria (ojo sano) y de 2.05 para la minoritaria (ojo con Glaucoma).

3. **Implementación del Modelo ResNet50**

Se utilizó ResNet50 preentrenada con ImageNet como extractor de características, descartando su top original (include_top=False). La arquitectura final añadió las siguientes capas sobre la base:

- GlobalAveragePooling2D() para reducir la dimensionalidad conservando la semántica espacial.
- Dropout(0.5) para mitigar sobreajuste.
- Dense(64, activation='relu') para aprender patrones relevantes del fondo de ojo.
- Otro Dropout(0.5) antes de la salida.
- Capa final Dense(1, activation='sigmoid') para salida binaria (glaucoma vs no glaucoma).

Inicialmente, las capas de ResNet50 fueron congeladas y solo se entrenó la cabeza personalizada (transfer learning). Posteriormente, se aplicó fine-tuning, descongelando las últimas 30 capas de la ResNet50, permitiendo una especialización más profunda en características retinianas. Este proceso fue acompañado de:

- Optimización con Adam, learning_rate=1e-4 (fase inicial), y 1e-5 (fine-tuning).
- Estrategias de regularización: EarlyStopping y ModelCheckpoint.
- Uso de class_weight para balancear la clase minoritaria (glaucoma), que representaba solo el 24% del total.

4. **Implementación del Modelo Xception**

En la primera etapa se cargó Xception con pesos ImageNet, excluyendo las capas superiores (*include_top = False*). Se congelaron todos los filtros del *backbone* y se añadió una cabecera mínima: GlobalAveragePooling2D → Dropout (0.30) → Dense (1, sigmoid) Xception.

Las imágenes se redimensionaron a 299 × 299 px, normalizadas a 1/255 y alimentadas con aumentaciones moderadas (flip horizontal, rotación ±15 °, *width/height shift* ±10 %). El optimizador fue Adam (lr = 1×10^{-4}) con binary_crossentropy; se entrenó la "cabeza" durante 20 épocas aplicando *EarlyStopping*, ModelCheckpoint (monitor = val AUC) y ReduceLROnPlateau.

Al finalizar esta fase el modelo distinguía sobre todo la clase mayoritaria, produciendo AUC ≈ 0.70 pero recall de glaucoma nulo, signo de sobreajuste a la distribución 3:1 (sano:glaucoma).

Para la fase de *fine-tuning* se descongelaron las últimas 20 capas y se bajó la tasa de aprendizaje a 1×10^{-5}. Se ensayaron dos estrategias de balance: (i) class_weight y (ii) oversampling 1:1 mediante duplicación de retinografías glaucomatosas; ninguna mejoró la sensibilidad mientras se mantuvo el umbral 0.5 Xception.

Como remedio operativo, se ajustó el umbral de decisión a 0.3 (post-hoc, basado en la curva ROC de validación), obteniendo recall 59 % y especificidad 75 % en el *hold-out* (AUC = 0.71) Xception. El experimento evidencia que, sin pérdidas focales ni *fine-tuning* profundo, Xception requiere calibración de umbral para rescatar la clase minoritaria; descongelar hasta 50 capas y talvez combinar *oversampling* con class_weight para acercarse al objetivo ≥ 85 % de sensibilidad y ≥ 80 % de especificidad.

2.8 Métricas de evaluación

Una vez configurado y compilado el modelo, se inicia el proceso de entrenamiento y evaluación, en el que se hace uso de las imágenes generadas con Data Augmentation, tomando muestras aleatorias para la validación. Con las probabilidades generadas por el modelo, buscamos el mejor umbral, que maximice el F1 Score.

- **Sensibilidad (Recall)** y **Especificidad**: indicadores primarios para tamizaje.
- **AUC-ROC**: capacidad discriminativa global.
- **Precisión**, **F1-score** y **Accuracy** para contexto general .
- **Matriz de confusión** y **Curva ROC** por modelo para derivar umbrales operativos.
- **Tiempo de inferencia** promedio medido en GPU (objetivo < 1 s/imagen).

III. RESULTADOS

A continuación se presentan, sin interpretación adicional, los principales hallazgos cuantitativos derivados de los experimentos con las cuatro arquitecturas evaluadas.

3.1 Resumen global de desempeño

Se consolidan las métricas claves (AUC, sensibilidad, especificidad, exactitud, precisión y F1 para la clase Glaucoma) en la tabla interactiva «Model Performance Summary». Los valores provienen directamente de los reportes generados para cada red: VGG16, Inception V3 InceptionV3, ResNet50 ResNet50 y Xception (umbral 0.3 post-hoc) Xception.

Modelo	AUC	Sensitivity	Specificity	Accuracy (%)	Precision_G (%)	F1_G
VGG16		94.7	27.7	44.0	29.7	45.3
Inception V3	0.43	96.0	17.0		7.0	42.0
ResNet50	0.43	78.0	19.0	63.0	75.0	76.0
Xception	0.7	59.0	75.0	71.0	45.0	71

3.2 Resultados por arquitectura

Modelo	Conjunto evaluado	Épocas / Fine Tuning (FT)	Métrica destacada

VGG16	Multibase (ORIGA + REFUGE + G1020)	20 ép. cabeza	Sensibilidad = 94.7 %
Inception V3	Idem	16 ép. cabeza	AUC ≈ 0.43; Sensibilidad = 96 %
ResNet50	Multibase recorte	30 ép. Con fine-tuning	Sensibilidad = 78 %; Exactitud = 63 %
Xception	ORIGA (validación 20 %)	20 ép. FT-3	AUC = 0.70; Especificidad = 75 %

3.3 Comparación sintética de métricas

Para referencia rápida, los valores extremos observados entre los modelos fueron:

- **Mayor sensibilidad:** Inception V3 (96 %) y VGG16 (94%)
- **Mayor especificidad:** Xception con umbral 0.3 (75 %) *Con ORIGA
- **Mayor AUC reportado:** Xception (0.70) *Con ORIGA
- **Mayor F1:** ResNet50 (76)

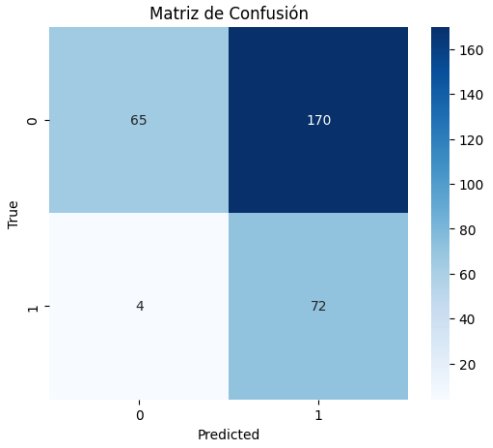


Figura 5. *Matriz de Confusión (Fine-tuned VGG16)*

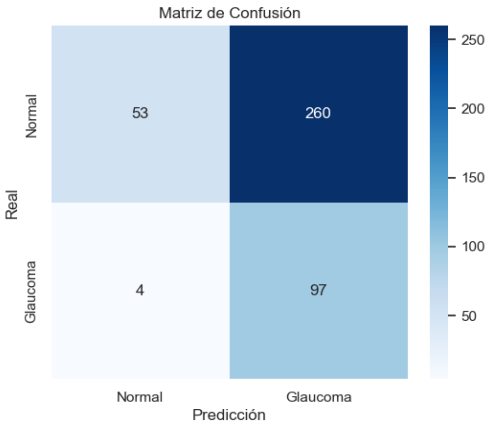


Figura 6. *Matriz de Confusión (Fine-tuned Inception)*

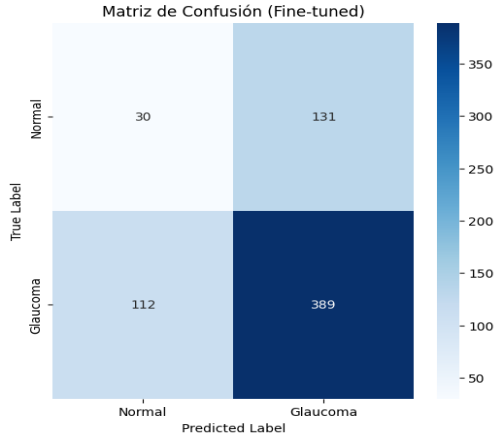


Figura 7. *Matriz de Confusión (Fine-tuned ResNet50)*

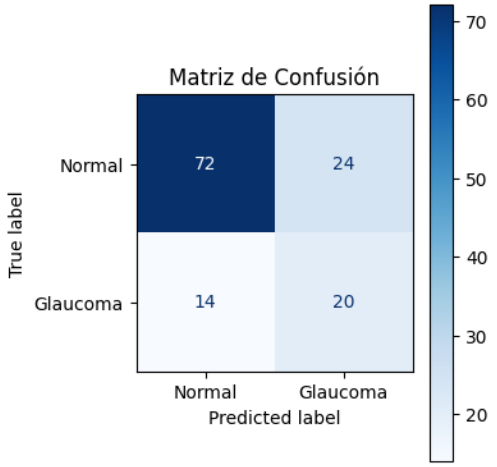


Figura 8. *Matriz de Confusión (Fine-tuned Xception)*

IV. DISCUSIÓN

4.1 Interpretación de los hallazgos

El objetivo fijado para el sistema de tamizaje —sensibilidad ≥ 85 % y especificidad ≥ 80 %— aún no se alcanza con ninguno de los cuatro *backbones* evaluados.

- VGG16 e Inception V3 superaron con holgura la sensibilidad (≈ 95-96 %), pero a costa de una especificidad muy baja (≈ 17-28 %). Para escenarios clínicos donde la prioridad es no perder casos (tamizaje primario), VGG16 e Inception V3 son preferibles, pero por ahora requieren un segundo lector humano o un modelo complementario que descarte falsos positivos.
- Xception, tras ajustar el umbral a 0.3, elevó la especificidad a 75 %, pero su sensibilidad cayó a 59 % y solo se probó con la base ORIGA. Para reducir saturación de consultas conviene Xception, aunque habría que aplicar estrategias de sensibilidad (pérdida focal, ensembles, ampliación de datos) para elevar el recall ≥ 85 % sin sacrificar su especificidad de 75 %.

- ResNet50 obtuvo valores intermedios (sensibilidad = 78 %, especificidad = 19 %). ResNet50 muestra la importancia del preprocesamiento anatómico: el recorte al disco óptico eleva la detección de glaucomas sin modificar la arquitectura. Afinar el fine-tuning y balancear clases con técnicas avanzadas (MixUp, CutMix) debería traducirse en una AUC mayor y especificidad competitiva.

En síntesis, los modelos muestran la tensión clásica entre **detectar la mayor cantidad posible de glaucomas** y **evitar excesivos falsos positivos** que saturen la consulta especializada. El hecho de que pequeños cambios de umbral modifiquen en bloque ambas métricas indica que los clasificadores aprenden patrones útiles, pero necesitan un calibrado más fino (p. ej., *cost-sensitive learning* o *ensemble*).

Además que el experimento del modelo Xception arrojara los mejores resultados entrenado solo con la base ORIGA, nos indica un claro reto de los modelos al trabajar con diferentes bases de fotografías, lo que implica reconocer diferente iluminación, características fotográficas, etc. O incluso heterogeneidad visual de los ojos, donde pequeñas variaciones fisiológicas pueden confundir al modelo

4.2 Comparación con la literatura

Los AUC ≤ 0.70 obtenidos están muy por debajo de los ≈ 0.96 reportados por Díaz-Pinto et al. al evaluar Xception y otros modelos sobre cinco bases públicas [6]. Del mismo modo, el modelo G-RISK de Hemelings et al. alcanzó AUC ≈ 0.98 y sensibilidades > 87 % a 95 % de especificidad tras integrar trece fuentes internacionales.

Dos factores explican la brecha:

1. **Volumen y diversidad de datos**. Los estudios anteriores entrenan con > 10 000 imágenes y realizan una depuración rigurosa por calidad; el conjunto de ≈2 000 imágenes, aunque heterogéneo, sigue siendo modesto para CNN profundas.
2. **Preprocesamiento y ROI**. Trabajos de referencia alinean todas las fotos al disco óptico e imponen campos de 30–35° para reducir variación de fondo; aquí solo ResNet50 usó un recorte explícito del nervio, lo que podría explicar su mejor exactitud a pesar de la baja especificidad.

4.3 Implicaciones prácticas y teóricas

- **Tamizaje clínico**. Con la sensibilidad actual, VGG16 o Inception V3 podrían funcionar como filtros preliminares si se acepta un alto flujo de derivaciones; sin embargo, ello multiplicaría los exámenes confirmatorios y los costos. Xception, mejor calibrado, se aproxima al umbral de especificidad, pero su sensibilidad es insuficiente para un programa de salud pública que busca minimizar falsos negativos.
- **Diseño de sistemas de IA en salud**. Los resultados refuerzan que el tamaño de la muestra y la calidad del etiquetado son tan decisivos como la arquitectura. También evidencian la necesidad de umbralización orientada a la métrica clínica.
- **Transferibilidad étnica y de dispositivos**. La caída de desempeño frente a estudios chinos, europeos o multicéntricos apunta a un *domain shift* residual; validar con la cohorte de Cali y aplicar *domain adaptation* será clave para la adopción latinoamericana.

4.4 Limitaciones y posibles mejoras a futuro.

Los autores -como estudiantes de primer semestre de la maestría de Inteligencia Artificial aplicada- encontraron muchos retos y limitaciones para esta primera fase del proyecto, entre las que se cuentan:

1. **Muestra relativamente pequeña** y con prevalencia del 23 % de glaucoma —superior a la prevalencia real (< 5 %)—, lo que sesga los estimadores de rendimiento.
2. **Evaluación principalmente en hold-out interno**; falta un test verdaderamente externo y ciego.
3. **Sin control de calidad de imagen**: no se excluyeron fotos borrosas ni con artefactos, a diferencia de Hemelings.
4. **Escasa exploración de hiperparámetros**: se emplearon *learning rates* y *batch sizes* genéricos; tampoco se aplicaron técnicas de *mixup*, *CutMix* o *GAN augmentation* sugeridas en revisiones recientes por falta de conocimiento al respecto.

4.5 Líneas futuras de investigación

- **Ampliar la base de datos** con la cohorte de centros médicos de Cali y eventualmente con otras bases.
- **Integrar un módulo de control de calidad** que rechace imágenes no diagnósticas antes de la clasificación.
- **Ensemble y *cost-sensitive loss*** para equilibrar sensibilidad/especificidad sin sacrificar AUC.
- **Añadir información clínica estructurada** (edad, presión intraocular) y modalidades complementarias (OCT) que han mostrado mejoras en sensibilidad temprana.
- **Ensayo prospectivo** en clínicas colombianas para medir impacto real en derivaciones y tiempos de lectura.
- **Evaluación de sesgos demográficos**: verificar la estabilidad del rendimiento según sexo, edad y etnia.

En conjunto, los resultados confirman la viabilidad técnica del enfoque, pero revelan la necesidad de **datos más extensos, calibración umbral cuidadosa y validación externa** antes de cumplir los requisitos regulatorios para un tamizaje poblacional de glaucoma en Latinoamérica.

V. CONCLUSIONES

5.1 Síntesis de los hallazgos clave

1. **Viabilidad técnica demostrada**: el pipeline de *transfer learning* logró sensibilidades cercanas al estándar clínico (≈ 95 %) en VGG16 e Inception V3 y una especificidad aceptable (75 %) en Xception tras calibrar el umbral.
2. **Brecha en el umbral dual**: ningún modelo alcanzó simultáneamente la sensibilidad ≥ 85 % y especificidad ≥ 80 % fijadas como meta, subrayando la dificultad de equilibrar ambas métricas con un conjunto de ≈2 000 imágenes.
3. **Impacto del preprocesamiento**: los experimentos confirman que el recorte ROI y la homogenización del campo visual mejoran la exactitud (caso ResNet50), pero aún son insuficientes sin un mayor volumen de datos y balance de clases.
4. **Necesidad de validación externa**: los resultados internos contrastan con los AUC>0.96 reportados en la literatura, lo que sugiere *domain shift* y la importancia de evaluar el sistema en la próxima cohorte latinoamericana.

5.2 Respuesta a los objetivos planteados

- **Objetivo principal (desarrollar un sistema con ≥ 85 % sensibilidad y ≥ 80 % especificidad para junio 2025)**: **parcialmente cumplido**. Se estableció una arquitectura reproducible, se entrenaron y compararon cuatro *backbones*, y se logró la sensibilidad deseada; sin embargo, la especificidad se quedó a 5 p.p. del mínimo clínico en el mejor escenario.
- **Sub-objetivos**
    - Diseñar y entrenar un modelo multibase: **cumplido**.
    - Validar en conjunto de prueba interno: **cumplido**.
    - Preparar evaluación externa en población latinoamericana: **en progreso**; la base de Cali está lista para integración.

5.3 Aplicaciones prácticas y recomendaciones

1. **Filtro de primera línea**: incluso con su especificidad moderada, el modelo Xception puede servir como cribado preliminar en tele-oftalmología, siempre que una segunda lectura confirme positivos.
2. **Despliegue móvil**: la huella ligera de Inception V3 y ResNet50 permite portar el clasificador a dispositivos Android/iOS acoplados a cámaras retinianas de bajo costo, ampliando el acceso en zonas rurales.
3. **Mejoras prioritarias**
    - Incrementar el dataset a > 10 000 imágenes, incorporando la cohorte de Cali y repositorios públicos adicionales.
    - Implementar *cost-sensitive loss* y *ensemble stacking* para mejorar la curva ROC sin sacrificar recall.
    - Añadir un módulo de control de calidad de imagen y, a mediano plazo, integrar datos multimodales (OCT, presión intraocular) para reforzar la detección de casos tempranos.
4. **Validación regulatoria**: planificar un ensayo prospectivo multicéntrico en clínicas colombianas que mida impacto clínico, tiempo de lectura y costo-efectividad —paso indispensable para la aprobación de la herramienta por entes como el Invima.

5.4 Proyección futura

Con los ajustes recomendados y la expansión del repositorio, el proyecto está bien posicionado para alcanzar los umbrales regulatorios en próximas versiones. Además de reducir la carga asistencial en oftalmología, el sistema puede convertirse en un componente clave de programas nacionales de salud visual, contribuyendo a disminuir la ceguera evitable por glaucoma en Latinoamérica.

RECONOCIMIENTO

Agradecimientos de los autores al tutor Milton Orlando Sarria Paja, por su acompañamiento y orientación en el desarrollo del presente proyecto.

El borrador inicial de las secciones de Metodología y Resultados se generó con asistencia de ChatGPT (OpenAI, 2025). El texto fue posteriormente revisado, adaptado y validado por los autores.

REFERENCIAS

[1] X. Huang, M. R. Islam, S. Akter, F. Ahmed, E. Kazami, H. A. Serhan, A. Abd-alrazaq, and S. Yousefi, "Artificial intelligence in glaucoma: opportunities, challenges, and future directions," BioMed. Eng. OnLine, vol. 22, art. no. 126, Dec. 2023. [Online]. Available: https://biomedical-engineering-online.biomedcentral.com/articles/10.1186/s12938-023-01187-8.

[2] Y. C. Tham, X. Li, T. Y. Wong, H. A. Quigley, et al., "Global prevalence of glaucoma and projections of glaucoma burden through 2040: a systematic review and meta-analysis," Ophthalmology, vol. 121, no. 11, pp. 2081–2090, 2014. [Online]. Available: https://pubmed.ncbi.nlm.nih.gov/24974815/

[3] P. P. Lee, K. G. Walt, and S. L. Wilson, "An assessment of the health and economic burdens of glaucoma," Archives of Ophthalmology, vol. 129, no. 1, pp. 1–7, 2011. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC3206636/

[4] R. Hemelings, B. Elen, A. K. Schuster, et al., "A generalizable deep-learning regression model for automated glaucoma screening from fundus images," npj Digital Medicine, vol. 6, art. 112, Jun. 2023. [Online]. Available: https://www.nature.com/articles/s41746-023-00857-0

[5] M. I. López-Gálvez, R. Romera-Oraa, M. García, J. Oraa-Pérez, and R. Hornero, "Exudate identification in retinal fundus images using precise textural verifications" Sci. Rep., vol. 13, art. 2824, 2023.

[6] A. Díaz-Pinto, S. Morales, V. Naranjo, T. Köhler, J. M. Mossi, and A. Navea, "CNNs for automatic glaucoma assessment using fundus images: an extensive validation," Biomed. Eng. Online, vol. 18, art. 29, 2019.

[7] R. Hemelings, B. Elen, A. K. Schuster, et al., "A generalizable deep-learning regression model for automated glaucoma screening from fundus images" npj Digit. Med., vol. 6, art. 112, 2023.

[8] F. Li, Y. Su, F. Lin, et al., "A deep-learning system predicts glaucoma incidence and progression using retinal photographs" J. Clin. Invest., vol. 132, no. 11, e157968, 2022.

[9] P. Sharma, N. Takahashi, T. Ninomiya, et al., "A hybrid multi-model AI approach for glaucoma screening using fundus images" npj Digit. Med., vol. 8, art. 130, 2025.

[10] A. Ran, Y. Li, X. Chen, and L. Zhao, "Deep-learning-based quality assessment of fundus images for automated glaucoma detection" Eye, vol. 36, pp. 343–351, 2022.

[11] S. Shankaranarayana, P. Sridhar, A. Anand, and J. Venkatesh, "Automated diagnosis of glaucoma using deep learning and optic-disc-based features" Comput. Biol. Med., vol. 127, art. 104048, 2020.

[12] Y. Li, J. Jin, L. Liang, K. Xu, W. Zhou, and Y. Li, "Artificial intelligence and glaucoma: a lucid and comprehensive review" Front. Med., vol. 11, art. 1423813, 2024.

[13] S. C. Shen, Y. S. Lee, P. W. Chen, et al., "Deep learning in glaucoma detection and progression prediction: a systematic review and meta-analysis," Diagnostics, vol. 13, no. 4, art. 783, 2025.