Implementación de sensores blandos (soft-sensors) en la industria de producción de penicilina

Felipe Guerra y Mavelyn Sterling
felipe.guerra@correounivalle.edu.co, mavelynsterling@gmail.com

Resumen - Este proyecto tiene como objetivo explorar la aplicación de redes neuronales en la optimización de procesos industriales dentro de la producción biofarmacéutica de penicilina. Se implementaron sensores blandos (soft-sensors) basados en modelos de aprendizaje automático para predecir variables clave del proceso. El conjunto de datos utilizado fue generado mediante IndPenSim, una simulación avanzada de fermentación con espectroscopia Raman, que reproduce un sistema de 100,000 litros. Se analizaron 100 lotes divididos en cuatro grupos, según la estrategia de control empleada: control basado en recetas, control por operadores, control avanzado con espectroscopia Raman, y lotes con fallos de proceso. Para cada grupo, se realizó una selección de variables utilizando técnicas estadísticas como regresión Lasso y regresión por mínimos cuadrados parciales (PLS). Posteriormente, se entrenaron modelos MLP independientes para cada conjunto de variables seleccionadas, permitiendo comparar el rendimiento predictivo de cada enfoque. Los resultados destacan el potencial de las redes neuronales como herramientas efectivas para la modelación de procesos complejos y su integración con sensores blandos para la mejora del control industrial en biotecnología.

Índice de Términos - Aprendizaje automático, Fermentación industrial de penicilina, IndPenSim, Sensores blandos.

I. Introducción

La producción biofarmacéutica, como la fermentación de penicilina, se caracteriza por su complejidad y variabilidad inherente, lo que representa un reto significativo para su monitoreo y control eficiente. En este contexto, la integración de técnicas de inteligencia artificial, como el aprendizaje automático y específicamente las redes neuronales, ha emergido como una solución prometedora para mejorar la predicción de variables críticas del proceso. Los sensores blandos (soft-sensors), que combinan modelos de ML con información en tiempo real, permiten estimar parámetros que no se pueden medir directamente, lo que abre nuevas posibilidades para la optimización del proceso.

Este proyecto se justifica por la creciente necesidad de herramientas inteligentes que permitan una mayor eficiencia, robustez y adaptabilidad en los sistemas de control de procesos biofarmacéuticos. Además, el uso de IndPenSim, una plataforma de simulación avanzada con espectroscopia Raman simulada, proporciona un entorno ideal para la experimentación y validación de estos métodos. En particular, se busca entender cómo diferentes estrategias de control afectan el comportamiento del sistema y cómo los modelos MLP pueden adaptarse a estas variaciones para generar predicciones precisas y confiables.

II. Definición del problema

La industria biofarmacéutica enfrenta desafíos complejos en la monitorización y control de procesos de fermentación, especialmente en la producción de penicilina, donde la dinámica es altamente no lineal, multivariable y dependiente del tiempo. Esta complejidad dificulta la predicción precisa de variables críticas como la concentración de penicilina (P: g/L), cuyo control es fundamental para garantizar la calidad del producto, minimizar pérdidas económicas y optimizar el rendimiento del proceso.

A pesar de los avances en automatización, muchas plantas aún operan bajo esquemas tradicionales basados en recetas predefinidas o ajustes manuales, que no responden de forma eficiente a las variaciones dinámicas del sistema. La ausencia de herramientas predictivas basadas en inteligencia artificial limita la capacidad de anticiparse a desviaciones del proceso, restringe la toma de decisiones en tiempo real y compromete la eficiencia operativa.

Este proyecto propone el desarrollo de un modelo de aprendizaje automático capaz de predecir la concentración de penicilina (P: g/L) a partir de un conjunto amplio de variables del proceso, que incluyen factores como tasa

de aireación, agitación, flujo de sustratos, temperatura, pH, concentración de oxígeno disuelto, tasa de consumo de oxígeno, evolución de dióxido de carbono, entre otras. Estas variables capturan de manera integral el estado del sistema y su influencia sobre la producción de penicilina, permitiendo la construcción de un modelo predictivo robusto y útil para la toma de decisiones en tiempo real.

III. OBJETIVOS

Objetivo General

Investigar el uso de redes neuronales (MLP) como sensores blandos (soft-sensors) para la predicción de variables clave en el proceso de producción de penicilina, con el fin de mejorar la eficiencia y robustez de los sistemas de control industrial.

Objetivos Específicos

- Realizar un análisis exploratorio de los lotes de producción simulados por IndPenSim, identificando patrones de comportamiento según la estrategia de control utilizada.
- Aplicar técnicas de selección de variables (Lasso y PLS) para identificar variables relevantes en cada grupo de lotes.
- Implementar modelos de redes neuronales (MLP) basados en las variables seleccionadas por cada técnica.
- Comparar el rendimiento predictivo de los modelos MLP construidos con distintas estrategias de selección de variables.
- Evaluar el potencial de los modelos MLP como sensores blandos para su aplicación futura en sistemas de control industrial en biotecnología.

IV. ÁRBOL DE PROBLEMAS

PROBLEMA CENTRAL
Falta de herramientas inteligentes para la predicción precisa de variables clave en procesos biofarmacéuticos como la producción de penicilina

CAUSAS PRINCIPALES	EFECTOS DIRECTOS	CONSECUENCIAS
- Uso de estrategias de control tradicionales (recetas u operadores)	- Predicciones inexactas de variables críticas	- Pérdidas económicas por ineficiencia en producción
- Ausencia de sensores blandos con modelos IA	- Dificultad en la detección temprana de fallos	- Variabilidad en la calidad del producto final
- Complejidad multivariable del proceso y falta de modelos predictivos adecuados	- Baja capacidad de respuesta del sistema de control	- Limitada capacidad de optimización del proceso

V. ESTADO DEL ARTE

1. **Desafíos modernos de monitoreo y control expuestos en un proceso de fermentación de referencia a escala industrial.**

   Este estudio tuvo como objetivo principal ampliar un modelo previo mecanicista estructurado de fermentación industrial de penicilina (100,000 L) y convertirlo en un gemelo digital denominado IndPenSim, implementado en MATLAB-GUI y con datos realistas para aplicaciones tipo big-

data. Se integraron espectroscopía Raman simulada (sensor InGaAs 993 nm), tres estrategias diferentes de control del proceso (control por receta, control manual por operadores, y control avanzado basado en espectroscopia Raman), y cuatro tipos específicos de fallos (fallos en agitador, aireación, alimentación de sustrato y sensores). Se utilizaron algoritmos estadísticos lineales, particularmente Regresión por Mínimos Cuadrados Parciales (PLS-R), para construir sensores blandos que predijeran la concentración de penicilina, obteniendo un RMSE aproximado de 0.10 g L^{-1}, considerado altamente preciso bajo condiciones nominales. Además, usando Análisis de Componentes Principales (PCA) con el estadístico de error de predicción cuadrático (SPE-PCA), identificaron claramente lotes anómalos generados por problemas en aireación o deriva del sensor de pH, con un éxito del 100 % en la detección temprana de estos fallos. Al integrar estos sensores blandos Raman en un controlador PI para la alimentación del ácido fenilacético (PAA), los autores demostraron que se puede incrementar hasta en un 20 % la producción anual de penicilina en comparación con el control tradicional basado en recetas. Concluyeron que IndPenSim representa una plataforma robusta y versátil para desarrollar y validar nuevas técnicas de control avanzado y PAT/QbD; sin embargo, destacaron como limitación la ausencia de algoritmos no lineales avanzados de inteligencia artificial y aprendizaje automático profundo, así como la falta de una comparación entre métodos avanzados para selección automática de variables [1].

2. Desarrollo de una simulación fed-batch a escala industrial

Este trabajo tuvo como objetivo construir y validar un modelo mecanicista estructurado detallado de una fermentación fed-batch industrial (100 m^3) para la producción de penicilina, usando cuatro compartimentos celulares específicos (A_0–A_4). El modelo incluyó balances dinámicos de biomasa, penicilina, sustrato, oxígeno disuelto (DO), CO_2 disuelto, nitrógeno y ácido fenilacético (PAA), incorporando inhibiciones clave relacionadas con niveles críticos de oxígeno disuelto (10 % y 30 %), concentración de CO_2, nitrógeno y PAA. Además, incluyó modelos empíricos para la cinética de hidrólisis de la penicilina dependiente del pH y temperatura (T), correlaciones para el coeficiente volumétrico de transferencia de oxígeno (kLa) dependientes de la viscosidad y del aceite antiespumante, y control PID para pH y temperatura. Los parámetros del modelo fueron estimados mediante mínimos cuadrados, y la sensibilidad paramétrica global identificó claramente los diez parámetros más influyentes sobre el proceso. La validación del modelo frente a datos industriales reales (10 lotes reales de fermentación) mostró un ajuste altamente preciso con R^2 superiores a 0.90 para los perfiles dinámicos de concentración de penicilina (rango de 0 a 36 g L^{-1}), biomasa y oxígeno disuelto (DO). El error medio absoluto en predicciones de volumen y gases de escape fue menor al 3 %. Los resultados revelaron que, al pasar de un control basado en operadores al control automático por recetas, la variabilidad introducida en la producción alcanzó aproximadamente ± 800 kg por lote. Finalmente, destacaron que, aunque el modelo reproduce fielmente las condiciones industriales, no incluye simulación de datos Raman, ni escenarios de fallos específicos ni integración con técnicas avanzadas de aprendizaje automático, lo cual es una limitación identificada [2].

3. Sensores blandos basados en modelos interpretables para fermentaciones fed-batch a escala industrial: aprendizaje a partir de simulaciones

En este trabajo, los autores buscaron evaluar el desempeño de sensores blandos interpretables para predecir la concentración de penicilina usando los 100 lotes simulados generados por IndPenSim. Se probaron cuatro algoritmos interpretables específicos: Árboles de regresión CART, árboles modelo M5, Random Forest y Cubist. La entrada para estos modelos consistió exclusivamente de variables disponibles en tiempo real (Fs, rpm, T, pH, DO, V, CO_2 en gas de salida y O_2 en gas de salida). La metodología involucró dividir los datos en entrenamiento (80 lotes) y prueba (20 lotes), y validar usando validación cruzada de 10 pliegues (10-fold CV). Las métricas de evaluación fueron el error absoluto medio (MAE), raíz del error cuadrático medio (RMSE), error cuadrático medio (MSE), y coeficiente de determinación (R^2). El algoritmo Cubist mostró el mejor rendimiento predictivo, logrando un $R^2 = 0.908$, MAE = 1.92 g L^{-1} y RMSE = 3.15 g L^{-1} utilizando un conjunto de 20 reglas y regresiones locales. Random Forest obtuvo resultados muy similares con $R^2 = 0.905$, MAE = 1.93 g L^{-1}. Los métodos más simples (CART y M5) presentaron menor desempeño, con un R^2 cercano a 0.78. Las conclusiones indicaron claramente que modelos

interpretables basados en reglas pueden competir satisfactoriamente con métodos más complejos, pero enfatizaron que ninguno de estos algoritmos consideró dependencias temporales o memoria histórica, como la proporcionada por redes neuronales recurrentes (RNN). También resaltaron que no realizaron una comparación formal entre distintos métodos avanzados de selección de variables, por lo que proponen como trabajo futuro la implementación de modelos recurrentes (LSTM o GRU) combinados con técnicas automáticas avanzadas de selección de variables como Lasso y PLS, con el objetivo de mejorar la robustez, precisión y capacidad de interpretación de los sensores blandos [3].

4. Modelo híbrido de red neuronal para simulación de fermentaciones en lote

Este trabajo tuvo como finalidad modelar la dinámica de una fermentación en lote de glucosa a etanol mediante un enfoque híbrido que acopla balances dinámicos de masa (biomasa, sustrato y etanol) con una red neuronal multicapa (MLP). El sistema experimental comprendió 28 ejecuciones realizadas en un fermentador operado en modo batch, con muestreos horarios de glucosa, biomasa, etanol y CO_2 disuelto. Para cada simulación se calcularon derivadas suavizadas y se generó un conjunto de 361 pares entrada-salida, donde las entradas fueron biomasa, sustrato, etanol y tiempo, y las salidas las velocidades cinéticas μ_x, μ_s y μ_p.

La MLP seleccionada adoptó la topología 3-7-3, con función sigmoide hiperbólica en la capa oculta y lineal en la de salida; los pesos se optimizaron usando el algoritmo de Levenberg-Marquardt después de normalizar todas las variables al rango (-1, 1). Se exploraron arquitecturas de 1 a 10 neuronas ocultas y se constató que 7 neuronas ofrecían el mejor compromiso entre capacidad predictiva y complejidad: el MSE global del modelo híbrido fue 0.0282, frente a 0.030 obtenido con la MLP sola, y los coeficientes de correlación alcanzaron un 0.999 para biomasa y 0.98 para etanol en el conjunto de prueba. Las diferencias entre valores experimentales y simulados se mantuvieron por debajo del 5 % a lo largo de todo el perfil de fermentación. Los autores subrayan que no se evalúa la robustez del modelo frente a cambios de escala ni frente a perturbaciones de proceso (p. ej., variaciones de pH o temperatura). Además, el enfoque no incluye procedimientos automáticos de selección de variables ni explora arquitecturas con memoria (RNN, LSTM) capaces de capturar dependencias temporales prolongadas, lo que limita su generalización a procesos industriales más complejos o a regímenes fed-batch [4].

VI. MATERIALES Y MÉTODOS

El estudio se basa en el análisis de datos generados por IndPenSim, una simulación matemática de un sistema de fermentación industrial de penicilina de 100,000 litros, que incluye un simulador de espectroscopia Raman. El archivo principal, 100_Batches_IndPenSim_V3.csv, contiene información detallada de 100 lotes de producción, representando diferentes condiciones operativas y estrategias de control.

Los lotes se agruparon según la estrategia de control utilizada:

- Lotes 1–30: controlados por recetas estándar,
- Lotes 31–60: bajo control manual de operadores,
- Lotes 61–90: controlados por un sistema APC con espectroscopia Raman,
- Lotes 91–100: contienen fallos deliberados para simular desviaciones del proceso.

Se realizó un análisis exploratorio de los datos para entender la dinámica de cada grupo. Posteriormente, se aplicaron técnicas de selección de variables como la regresión Lasso y la regresión por mínimos cuadrados parciales (PLS) para identificar las variables más relevantes en cada grupo. Para cada conjunto de variables seleccionadas, se construyeron y entrenaron modelos de redes neuronales (MLP), permitiendo realizar comparaciones entre enfoques.

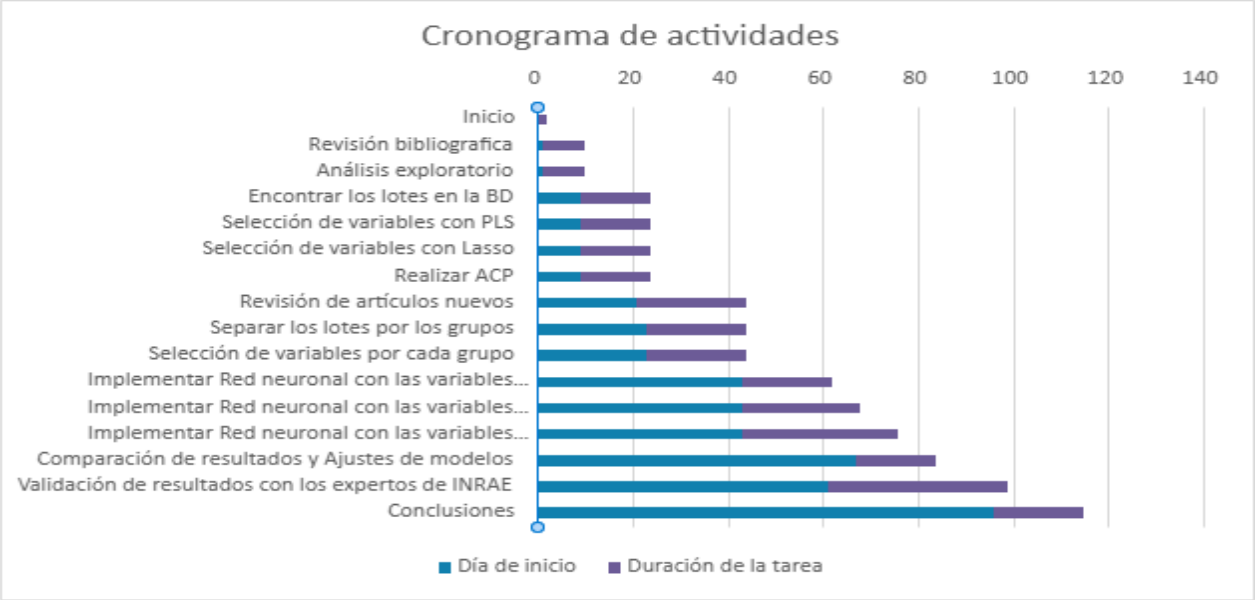
Las herramientas empleadas incluyeron Python, con librerías como Pandas, NumPy, Scikit-learn y TensorFlow/PyTorch. Los datos fueron normalizados y divididos en conjuntos de entrenamiento y prueba. Los

modelos se evaluaron con métricas de error como el RMSE y el coeficiente de determinación R^2, para determinar su precisión predictiva y capacidad generalizante.

VII. Plan de actividades y cronograma

El siguiente plan de actividades y cronograma es planteado paralelizando tareas.

Posición	Fecha de inicio	Fecha de finalización	Hito o actividad
1	17/03/2025	18/03/2025	Inicio
2	18/03/2025	26/03/2025	Revisión bibliografica
3	18/03/2025	26/03/2025	Análisis exploratorio
4	26/03/2025	09/04/2025	Encontrar los lotes en la BD
5	26/03/2025	09/04/2025	Selección de variables con PLS
6	26/03/2025	09/04/2025	Selección de variables con Lasso
7	26/03/2025	09/04/2025	Realizar ACP
8	07/04/2025	29/04/2025	Revisión de artículos nuevos
9	09/04/2025	29/04/2025	Separar los lotes por los grupos
10	09/04/2025	29/04/2025	Selección de variables por cada grupo
11	29/04/2025	17/05/2025	Implementar Red neuronal con las variables seleccionadas con PLS
12	29/04/2025	23/05/2025	Implementar Red neuronal con las variables seleccionadas con Lasso
13	29/04/2025	31/05/2025	Implementar Red neuronal con las variables seleccionadas en estudios anteriores
14	23/05/2025	08/06/2025	Comparación de resultados y Ajustes de modelos
15	17/05/2025	23/06/2025	Validación de resultados con los expertos de INRAE
16	21/06/2025	09/07/2025	Conclusiones



VIII. METODOLOGÍA

A. Análisis Exploratorio

El análisis exploratorio constituye una etapa fundamental para comprender la calidad, estructura y comportamiento inicial de los datos recolectados durante el proceso de fermentación. En primer lugar, se evaluó la calidad de los datos mediante estadísticas descriptivas, análisis de correlación entre variables y revisión de valores faltantes, lo cual permitió identificar patrones, relaciones significativas y posibles inconsistencias. Posteriormente, se realizó un proceso de selección de datos enfocado en conservar únicamente las observaciones relevantes y representativas para el estudio, excluyendo registros incompletos o fuera de rango. Finalmente, se definió un subconjunto de variables clave con base en su relevancia biotecnológica, su contribución al modelo predictivo de producción de penicilina y su disponibilidad durante todo el ciclo del bioproceso. Esta etapa permitió sentar las bases para el modelado posterior y asegurar la integridad analítica del estudio.

B. Calidad de la exploración

El conjunto de datos original está compuesto por 113.935 registros y 2.239 variables, de las cuales 2.225 son de tipo float64 y 14 de tipo int64, con un tamaño total de aproximadamente 1.9 GB en memoria. Debido a la alta dimensionalidad del conjunto, se realizó una selección inicial restringida a las primeras 36 variables, correspondientes a parámetros directamente involucrados en el bioproceso de producción de penicilina. Esta selección incluye variables operacionales, químicas y biológicas que se consideran relevantes para la dinámica fermentativa y el comportamiento del cultivo. La evaluación de la calidad de los datos se centró en tres aspectos: la distribución estadística de las variables, el grado de correlación entre ellas y la presencia de valores faltantes o inconsistentes. Este diagnóstico permitió confirmar la viabilidad del subconjunto seleccionado para su uso en las etapas posteriores de análisis y modelado.

La **Tabla 1** presenta un resumen estadístico descriptivo de las principales variables monitorizadas durante el proceso de fermentación para la producción de penicilina. Se incluyen medidas de tendencia central (media y mediana), dispersión (desviación estándar) y rango (mínimo y máximo) para cada parámetro. Las variables de control del proceso, como pH, temperatura, aireación y agitación, muestran valores medios estables con baja variabilidad, lo que evidencia un adecuado control operativo. Por otro lado, variables asociadas al metabolismo microbiano y a la producción, como la concentración de penicilina, oxígeno disuelto y consumo de oxígeno, presentan mayor dispersión, lo que sugiere una dinámica biológica compleja y fases diferenciadas dentro del cultivo. Este análisis permite identificar tendencias clave, evaluar la estabilidad del proceso y sirve como base para modelos predictivos o sistemas de control avanzados.

Variable	Unidad	Media (± DE)	Mediana	Mín – Máx	Interpretación
Tiempo	h	114.8 ± 67.0	114.0	0.2 – 290.0	Tiempo medio de fermentación, con alta variabilidad.
Tasa de aireación (Fg)	L/h	65.2 ± 11.7	65.0	20.0 – 75.0	Suministro constante de oxígeno.
RPM del agitador	RPM	100.0 ± 0.0	100.0	100.0 – 100.0	Velocidad fija, completamente automatizada.
Tasa de alimentación de azúcar (Fs)	L/h	76.7 ± 25.7	80.0	2.0 – 150.0	Controlada por demanda metabólica.
Flujo de ácido (Fa)	L/h	0.07 ± 0.55	0.0	0.0 – 13.0	Ajustes puntuales del pH.
Flujo de base (Fb)	L/h	61.3 ± 45.0	55.4	0.0 – 225.0	Principal método de control de pH.
Agua calefacción/enfriamiento (Fc)	L/h	74.3 ± 108.0	34.4	0.0001 – 1500.0	Cambios térmicos intensos en ciertos momentos.
pH	pH	6.50 ± 0.07	6.50	5.40 – 6.77	Controlado eficientemente.
Temperatura (T)	K	298.0 ± 0.2	297.99	296.84 – 302.18	Estable, ideal para crecimiento microbiano.
Penicilina (P)	g/L	14.3 ± 9.9	14.38	~0 – 36.18	Producción variable, pero eficiente.
Oxígeno disuelto (DO2)	mg/L	12.6 ± 1.5	12.64	1.00 – 16.51	Buen nivel de oxigenación.
Substrato (S)	g/L	4.08 ± 13.3	0.0016	0.000006 – 115.27	Alta variabilidad por alimentación discontinua.
Consumo oxígeno (OUR)	g/min	0.191 ± 0.0047	0.191	0.129 – 0.228	Indicador metabólico estable.
% CO_2 en gas residual	%	1.44 ± 0.50	1.60	0.075 – 7.12	Representa respiración microbiana.
Viscosidad (offline)	cP	51.5 ± 24.1	53.15	4.08 – 117.9	Mayor viscosidad implica mayor biomasa o espuma.
Volumen del reactor (V)	L	73313 ± 8599	75770	56549 – 95716	Volumen ajustado durante el proceso.
Biomasa (offline)	g/L	18.8 ± 7.0	21.45	0.39 – 27.9	Buena acumulación celular.
Tasa de evolución de carbono (CER)	g/h	14.4 ± 10.3	14.57	~0 – 36.18	Alta actividad metabólica respiratoria.

Tabla 1. Estadísticas descriptivas de las variables operacionales y biológicas durante la fermentación de penicilina.

Durante la revisión de valores faltantes, se identificó que cinco variables presentaban un porcentaje de ausencia superior al 98 %, específicamente: PAA concentration offline, NH_3 concentration offline, Offline Penicillin concentration, Offline Biomass concentration y Viscosity (offline). Estas variables corresponden a mediciones tomadas al final del bioproceso o en condiciones fuera de línea, utilizadas principalmente con fines de validación y control de calidad. Debido a su alta proporción de valores ausentes y tras consultar con expertos del proceso, se concluyó que dichas mediciones no están disponibles en tiempo real ni de forma continua, por lo que no fueron incluidas en los modelos predictivos desarrollados. Esta decisión permitió asegurar la coherencia temporal y operativa de los datos utilizados, priorizando variables que están disponibles de forma regular durante la operación del bioreactor.

Para el análisis de correlación entre la concentración de penicilina y las distintas variables del proceso de fermentación se presenta en forma de un mapa de calor. En este, se observa una escala cromática que permite distinguir la intensidad y dirección de las correlaciones:

- Rojo oscuro (correlación fuerte, > 0.7): indica una asociación directa y significativa con la producción de penicilina.

- Rojo medio (correlación moderada, entre 0.4 y 0.7): refleja una relación relevante pero no determinante.

- Blanco o gris (correlación débil, entre -0.4 y 0.4): sugiere ausencia de relación clara.

- Azul oscuro (correlación negativa fuerte, < -0.4): muestra que estas variables tienden a disminuir cuando la producción de penicilina aumenta.

1. Variables con correlación positiva fuerte
Variables como el tiempo de fermentación (r = 0.87), la biomasa medida offline (r = 0.79), la viscosidad del medio (r = 0.79), la tasa de evolución de carbono (r = 0.74) y la tasa de aireación (r = 0.71) muestran una fuerte correlación con la concentración de penicilina. Esto sugiere que el crecimiento celular y el metabolismo activo juegan un papel central en la síntesis del antibiótico. Asimismo, la alta correlación con el peso del biorreactor y la propia medición offline de penicilina confirma esta tendencia.

2. Variables con correlación moderada
La producción de CO_2 en el gas de salida (r = 0.62), el flujo de alimentación de azúcar (r = 0.47) y el flujo de PAA (r = 0.45) muestran correlaciones moderadas. Estas variables, aunque no determinantes, participan activamente en el sostenimiento de condiciones óptimas del proceso.

3. Variables con correlación débil
Variables como la tasa de consumo de oxígeno (OUR) (r = 0.26), el flujo de agua de inyección/dilución (r = 0.18) o la presión del cabezal de aire (r = 0.14) presentan relaciones débiles con la producción de penicilina. Esto indica que su influencia sobre el resultado final es limitada o indirecta.

4. Variables con correlación negativa
El flujo de agua de calefacción/enfriamiento (r = -0.48), la concentración de oxígeno disuelto (DO_2) (r = -0.33) y la temperatura (r = -0.28) muestran correlaciones negativas. Estos factores podrían indicar condiciones desfavorables cuando se encuentran fuera de su rango óptimo, sugiriendo que el exceso de oxígeno disuelto o fluctuaciones térmicas pueden comprometer la productividad del proceso.

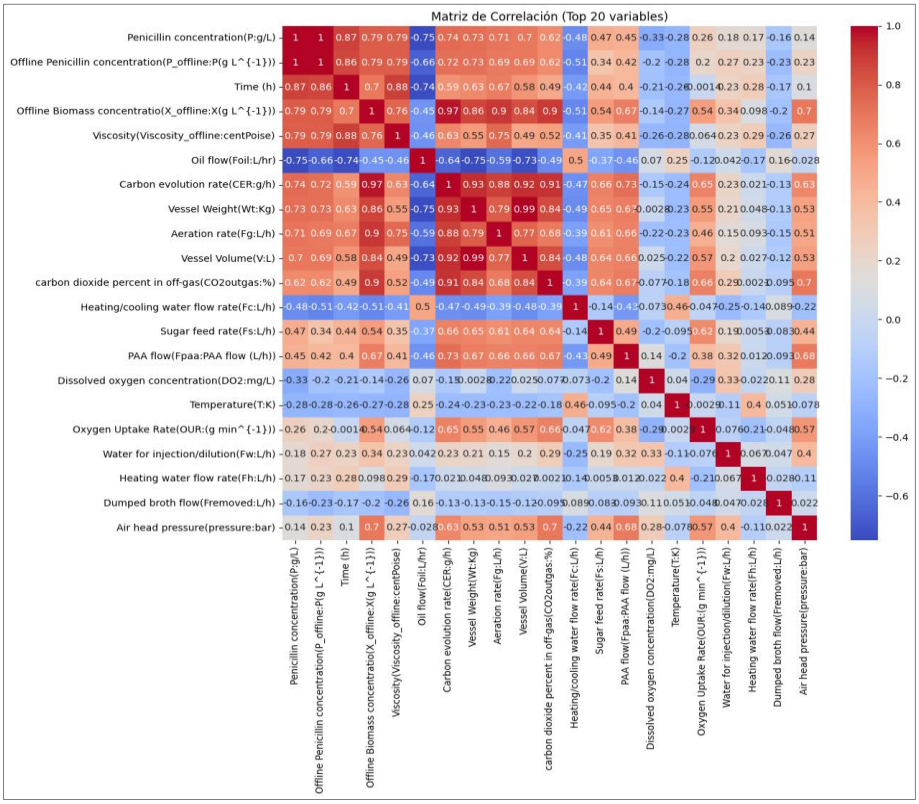


Figura 1. Análisis de correlación de las variables respecto a la Penicilina

C. Selección de datos

Con el fin de estructurar adecuadamente el conjunto de datos para su análisis, se implementó un procedimiento sistemático para identificar los distintos lotes de fermentación (batches) a partir de la variable `Time (h)`. Se consideró como indicador de inicio de lote el valor constante de 0.2 horas, correspondiente al primer registro de cada corrida. A partir de estos puntos de reinicio, se delimitaron 100 lotes independientes, cada uno representando un ciclo completo de producción.

Para cada lote, se realizó una fase de preprocesamiento que incluyó la eliminación de variables con más del 50 % de datos faltantes y la imputación de los valores restantes mediante la mediana. Esto garantizó la consistencia interna de cada lote y la comparabilidad entre ellos. Una vez limpios, los lotes fueron clasificados en cuatro grupos según la estrategia de control aplicada durante el proceso:

- **Receta**: 30 lotes controlados automáticamente mediante recetas predefinidas.
- **Operadores**: 30 lotes bajo control manual por parte del personal operativo.
- **APC_Raman**: 30 lotes asistidos con espectroscopía Raman y control avanzado de procesos (APC).
- **Fallas**: 10 lotes identificados con eventos de falla o desviaciones críticas.

Esta segmentación permite comparar el desempeño del proceso bajo distintas modalidades operativas y establecer inferencias más precisas sobre los factores que influyen en la producción de penicilina.

D. Planteamiento de Hipótesis

La implementación de sensores blandos basados en redes neuronales de tipo perceptrón multicapa (MLP), entrenados con variables clave seleccionadas mediante técnicas estadísticas avanzadas (regresión Lasso y regresión por mínimos cuadrados parciales - PLS), permitirá obtener predicciones significativamente más

precisas de la concentración de penicilina (P: g/L) en procesos de fermentación industrial simulados mediante IndPenSim, en comparación con métodos convencionales y estrategias actuales de control.

A partir de esta hipótesis general, se plantean las siguientes sub-hipótesis específicas para guiar la investigación y los experimentos:

- **Sub-hipótesis sobre selección de variables:** La selección de variables realizada mediante técnicas estadísticas avanzadas (Lasso y PLS) identificará consistentemente un conjunto reducido de variables operativas clave que expliquen eficazmente la variabilidad observada en la producción de penicilina bajo diferentes condiciones de control del proceso.

- **Sub-hipótesis sobre desempeño predictivo del modelo:** Los modelos basados en redes neuronales MLP que utilizan las variables seleccionadas tendrán un desempeño predictivo significativamente superior, reflejado en mejores métricas de evaluación (menor RMSE y mayor R^2), en comparación con modelos lineales tradicionales y otras técnicas interpretables previamente implementadas.

E. Selección de variables para los modelos

Para determinar las variables más relevantes que explican la producción de penicilina bajo diferentes estrategias de control, se aplicaron dos métodos de selección de características: regresión Lasso con validación cruzada (LassoCV) y regresión por mínimos cuadrados parciales (PLSRegression). Ambos métodos se aplicaron de manera independiente a cada uno de los cuatro segmentos definidos (Receta, Operadores, APC_Raman y Fallas), a partir de los conjuntos de datos previamente preprocesados y balanceados. Lasso se utilizó para seleccionar automáticamente las variables con mayor capacidad predictiva, eliminando aquellas con coeficientes nulos. En paralelo, PLS permitió obtener un ranking de las variables con mayor influencia, de las cuales se extrajeron las diez más relevantes para cada segmento.

Este enfoque doble ofreció una visión robusta sobre las variables determinantes para la predicción de la concentración de penicilina, considerando tanto la capacidad predictiva directa (Lasso) como la contribución latente a la variabilidad del sistema (PLS). Como resultado, se identificaron patrones comunes entre segmentos, destacándose variables operacionales clave como Oil flow, Cooling/Heating water flow, Vessel Volume, Aeration rate, DO_2, CER y OUR. Estas variables reflejan tanto el entorno físico del biorreactor como los procesos metabólicos involucrados en la síntesis del antibiótico. La coherencia de estos resultados fue validada con expertos del proceso, lo que permitió confirmar su relevancia biotecnológica y su idoneidad para la construcción de modelos predictivos específicos por tipo de control.

Segmento	Variables seleccionadas por Lasso	Variables más importantes según PLS (Top 10)
Receta	Oil flow, CER, Vessel Weight, Aeration rate, Vessel Volume, CO_2 outgas, Cooling/Heating water, Sugar feed, PAA flow, DO_2, Temp, OUR, Water injection, Heating water, Dumped broth, Air head pressure	Vessel Volume, CER, OUR, Cooling/Heating water, Vessel Weight, Air head pressure, Heating water, Aeration rate, DO_2, Oil flow
Operadores	Oil flow, Vessel Weight, Aeration rate, CO_2 outgas, Sugar feed, PAA flow, DO_2, Temp, OUR, Water injection, Heating water, Air head pressure	Vessel Volume, Cooling/Heating water, CER, Vessel Weight, OUR, Heating water, Air head pressure, Aeration rate, DO_2, Oil flow
APC_Raman	Oil flow, CER, Vessel Weight, Aeration rate, Vessel Volume, CO_2 outgas, Cooling/Heating water, Sugar feed, PAA flow, DO_2, Temp, OUR, Water injection, Heating water, Dumped broth, Air head pressure	Vessel Volume, CER, OUR, Cooling/Heating water, Vessel Weight, Air head pressure, Aeration rate, Heating water, DO_2, Oil flow

Fallas	Oil flow, CER, Aeration rate, Vessel Volume, CO_2 outgas, Cooling/Heating water, Sugar feed, PAA flow, DO_2, Temp, OUR, Water injection, Heating water, Dumped broth, Air head pressure	Heating water, OUR, Temp, CO_2 outgas, Cooling/Heating water, Aeration rate, Vessel Volume, CER, Vessel Weight, Oil flow

Tabla 2. Variables seleccionadas por Lasso y PLS para cada estrategia de control

F. Segmentación de los datos

Se crearon cuatro subconjuntos, cada uno representando una **estrategia operativa**:

1. **Receta** – ejecución estándar del protocolo.
2. **Operadores** – ajustes manuales hechos por el personal.
3. **APC Raman** – control avanzado basado en espectroscopía Raman.
4. **Fallas** – corridas con eventos anómalos o errores.

El grupo **Fallas** se retuvo para evaluar robustez, pero el análisis principal se centra en los tres primeros, que describen condiciones estables y reproducibles.

G. Búsqueda de hiper parámetros

Para cada subconjunto se entrenó una red neuronal MLP. El espacio de búsqueda contempló seis hiper parámetros:

Hiper parámetro	Valores probados	Cardinalidad
units	32,64,128,256	4
layers	1,2,3	3
activation	relu,tanh,swish	3
learning-rate	0.0001, 0.001,0.005,0.01	4
batch-size	16,32,64	3
epochs	30, 50,100,150	4

Combinaciones totales=4×3×3×4×3×4=1728

Para cada subconjunto de datos se entrenó una red neuronal MLP utilizando una búsqueda aleatoria de hiper parámetros. El espacio de búsqueda definido contempló seis hiper parámetros clave: número de unidades por capa (units), número de capas ocultas (layers), función de activación (activation), tasa de aprendizaje (learning-rate), tamaño de batch (batch-size) y número de épocas de entrenamiento (epochs). Cada uno de estos hiperparámetros tomó múltiples valores discretos, generando un total de 1728 combinaciones posibles.

Aplicar una búsqueda exhaustiva (Grid Search) habría requerido entrenar 1728 modelos por grupo, lo cual resultaría en un costo computacional elevado (aproximadamente 6,912 entrenamientos para cuatro grupos). Por esta razón, se optó por una estrategia más eficiente: RandomizedSearchCV, con la que se muestrearon únicamente 50 configuraciones aleatorias por grupo (aproximadamente 200 entrenamientos en total), cubriendo cerca del 3 % del espacio total, pero preservando una alta probabilidad de encontrar combinaciones cercanas al óptimo. Cada configuración fue evaluada mediante validación cruzada de 3 pliegues para mitigar la varianza en las métricas de evaluación.

IX. RESULTADOS

En esta sección se presentan los resultados obtenidos tras el desarrollo y evaluación de los modelos predictivos de concentración de penicilina, considerando distintas estrategias de selección de variables y segmentación

operativa del proceso. Se comparan tres enfoques principales: el primero basado en variables definidas por expertos y estudios previos; el segundo utilizando variables seleccionadas automáticamente mediante regresión Lasso; y el tercero fundamentado en la reducción de dimensionalidad a través de regresión por mínimos cuadrados parciales (PLS). Cada enfoque fue aplicado a los distintos segmentos operativos definidos en el sistema, permitiendo evaluar la capacidad explicativa y la robustez de los modelos en contextos diversos de control y operación del biorreactor.

A. Modelo con las variables seleccionadas en los expertos en estudios anteriores

- ***Variables de entrada***

Según el estado del arte en fermentación industrial, se eligieron diez variables que capturan la dinámica fisicoquímica y operativa del biorreactor:

Variable	Descripción
Fs	Flujo de sustrato (feed rate)
Agitación	Velocidad de agitación (rpm)
T	Temperatura (°C)
pH	Potencial de hidrógeno
DO	Oxígeno disuelto (%)
V	Volumen de cultivo (L)
CO_2_og	CO_2 en salida de gas (%)
O_2_og	O_2 en salida de gas (%)
P	Presión (bar)
Lote	Identificador del lote

Los modelos construidos a partir de estas variables demostraron una clara diferenciación en el desempeño predictivo según la estrategia operativa evaluada. El modelo entrenado con datos del grupo APC Raman alcanzó el mejor rendimiento, obteniendo un R^2 de 0.957, un MSE de 4.643 y el MAE más bajo (1.435) entre todos los segmentos. Este resultado sugiere que la información espectroscópica derivada del control avanzado proporciona señales altamente representativas del comportamiento del proceso, lo cual, combinado con una arquitectura configurada con 32 unidades, tasa de aprendizaje de 0.005, 150 épocas y batch size de 64, permitió una convergencia fina y eficiente del modelo.

Por su parte, los modelos correspondientes a los grupos Receta y Operadores compartieron la misma configuración arquitectónica (64 unidades, learning rate de 0.001, 50 épocas y batch size de 16), alcanzando coeficientes de determinación de 0.922 y 0.890, respectivamente. A pesar del diseño común, los errores fueron ligeramente superiores (MAE entre 1.9 y 2.2), lo cual puede atribuirse al mayor grado de variabilidad introducida por la intervención manual de los operarios en comparación con la ejecución estandarizada de la receta.

En contraste, el modelo aplicado al grupo Fallas arrojó un R^2 negativo (-3.538) y errores significativamente elevados (RMSE ≈ 6.9; MAE = 4.221), lo que evidencia la imposibilidad de representar adecuadamente las condiciones anómalas mediante un modelo ajustado principalmente a situaciones nominales. Estos hallazgos destacan la necesidad de construir modelos especializados para la detección y gestión de eventos fuera de lo esperado, al tiempo que refuerzan la eficacia del control automatizado APC Raman como estrategia para la optimización de la producción de penicilina.

Asimismo, se entrenó un modelo general a partir del conjunto completo de datos sin segmentación, el cual alcanzó un desempeño aceptable (R^2 = 0.897; MAE = 2.079), aunque inferior al observado en los modelos específicos por grupo. La siguiente tabla resume los hiper parámetros óptimos y métricas de evaluación para cada caso:

Grupo	Units	Learning Rate	Layers	Epochs	Batch Size	Activation	MSE	RMSE	R^2	MAE
Receta	64	0.001	3	50	16	tanh	8.448	2.907	0.922	1.916
Operadores	64	0.001	3	50	16	tanh	11.208	3.348	0.890	2.212
APC_Raman	32	0.005	3	150	64	tanh	4.643	2.155	0.957	1.435
Fallas	32	0.005	3	150	64	tanh	47.997	6.928	-3.538	4.221
Todos los grupos	256	0.0001	2	30	16	tanh	10.944	3.308	0.897	2.079

B. Modelo con la selección de variables por medio de la regresión Lasso

A partir de las variables seleccionadas mediante regresión Lasso con validación cruzada (LassoCV), se entrenaron modelos de redes neuronales multicapa (MLP) independientes para cada uno de los cuatro segmentos definidos: Receta, Operadores, APC_Raman y Fallas. Este enfoque permitió reducir la dimensionalidad del conjunto de datos, eliminando automáticamente aquellas variables con coeficientes nulos y conservando únicamente las de mayor capacidad predictiva. Al aplicar penalización L1 sobre los coeficientes, se logró disminuir el riesgo de sobreajuste y mejorar la interpretabilidad de los modelos.

Los resultados obtenidos evidencian un buen desempeño general, con especial destaque en los segmentos APC_Raman y Operadores, cuyos modelos alcanzaron coeficientes de determinación (R^2) de 0.974 y 0.938, respectivamente. En el grupo Receta, el modelo obtuvo un R^2 de 0.898, también indicativo de una sólida capacidad explicativa. Sin embargo, el grupo Fallas presentó un desempeño significativamente inferior, con un R^2 negativo (-0.908), lo que refleja la alta variabilidad y complejidad inherente a este tipo de registros anómalos.

Adicionalmente, se entrenó un modelo general utilizando un conjunto combinado de todos los segmentos. Este modelo logró un R^2 de 0.919 y un MAE de 1.691, demostrando una capacidad predictiva competitiva en comparación con los modelos específicos por segmento. La siguiente tabla resume los hiper parámetros óptimos y las métricas de evaluación obtenidas para cada grupo:

Grupo	Units	Learning Rate	Layers	Epochs	Batch Size	Activation	MSE	RMSE	R^2	MAE
Receta	32	0.005	3	150	64	tanh	11.055	3.325	0.898	2.082
Operadores	64	0.001	3	50	16	tanh	6.333	2.517	0.938	1.638
APC_Raman	32	0.005	3	150	64	tanh	2.849	1.688	0.974	1.156
Fallas	32	0.005	3	150	64	tanh	20.179	4.492	-0.908	2.824
Todos los grupos	128	0.0001	2	100	32	swish	8.528	2.920	0.919	1.691

C. Modelo con la selección de variables por medio de regresión PLS

A partir de las diez variables más influyentes seleccionadas mediante regresión por mínimos cuadrados parciales (PLSRegression) para cada segmento, se entrenaron modelos MLP personalizados con ajuste de hiperparámetros mediante RandomizedSearchCV. Este enfoque permitió capturar relaciones latentes entre las variables predictoras y la concentración de penicilina, lo cual es especialmente útil en contextos con alta multicolinealidad y complejidad no lineal.

Los resultados evidenciaron un buen desempeño predictivo en tres de los cuatro grupos evaluados. El modelo para el grupo Receta alcanzó un R^2 de 0.942 y un MAE de 1.611, reflejando una alta capacidad explicativa con

bajo error absoluto. En APC_Raman, el modelo también mostró una alta precisión ($R^2 = 0.971$), validando la relevancia de las variables seleccionadas por PLS para condiciones de control avanzado. El grupo Operadores, aunque con mayor complejidad en las decisiones manuales, logró un R^2 de 0.888 y un MAE de 2.155, lo que indica una adecuada generalización del modelo.

Por otro lado, el grupo Fallas presentó el peor rendimiento ($R^2 = -1.459$), lo cual sugiere que los eventos anómalos y la variabilidad no sistemática de este segmento dificultan la capacidad de predicción del modelo, incluso con selección supervisada de variables.

Finalmente, se entrenó un modelo general sobre todos los segmentos combinados usando las variables PLS compartidas. Este modelo mostró un desempeño competitivo ($R^2 = 0.939$, MAE = 1.631) y podría representar una alternativa viable cuando no se dispone de una clasificación previa por segmento.

Grupo	Units	Learning Rate	Layers	Epochs	Batch Size	Activation	MSE	RMSE	R^2	MAE
Receta	64	0.001	3	50	16	tanh	6.321	2.514	0.942	1.611
Operadores	32	0.005	3	150	64	tanh	11.422	3.380	0.888	2.155
APC_Raman	64	0.001	3	50	16	tanh	3.121	1.767	0.971	1.236
Fallas	32	0.005	3	150	64	tanh	26.009	5.100	-1.459	3.167
Todos los grupos	128	0.001	1	50	64	relu	6.496	2.549	0.939	1.631

X. Discusiones

El análisis comparativo entre las tres estrategias de selección de variables (selección basada en expertos, Lasso y PLS) permitió evidenciar fortalezas y limitaciones de cada enfoque, tanto a nivel de segmentos individuales como en el modelo general.

1) Comparación por segmentos

En términos generales, el segmento controlado por APC con espectroscopia Raman mostró consistentemente el mejor desempeño predictivo en todos los modelos, con $R^2 \geq 0.957$ y MAE ≤ 1.435. Esta superioridad puede atribuirse a la riqueza informativa de los datos obtenidos mediante espectroscopía Raman, que permiten capturar con mayor fidelidad la dinámica del bioproceso. De hecho, tanto el modelo con variables expertas como los modelos con variables seleccionadas por Lasso y PLS confirmaron este patrón de precisión, siendo el modelo Lasso el que alcanzó el mejor R^2 (0.974) y el menor MAE (1.156) en este grupo.

El segmento "Receta", basado en una ejecución estandarizada del proceso, presentó buenos niveles de desempeño predictivo, con R^2 entre 0.898 y 0.942 según la técnica empleada. Aquí, la regresión PLS se destacó como la técnica con mayor precisión, lo que sugiere que la capacidad de PLS para capturar relaciones latentes es especialmente útil en entornos con menor variabilidad operativa.

El grupo "Operadores", caracterizado por la intervención humana directa, mostró un desempeño más modesto (R^2 entre 0.888 y 0.938), posiblemente debido a la mayor heterogeneidad introducida por decisiones manuales. En este grupo, la selección Lasso se comportó mejor, sugiriendo que su capacidad para identificar un subconjunto de variables clave más ajustado puede ser beneficiosa frente a esta variabilidad.

En contraste, el grupo "Fallas" presentó dificultades significativas para todos los modelos. Ninguna de las técnicas logró una generalización adecuada, obteniendo R^2 negativos en todos los casos (hasta -3.538 con variables expertas). Este comportamiento refuerza la necesidad de modelos especializados para detección de anomalías, dada la no linealidad y la naturaleza impredecible de los eventos de fallo.

2) Comparación del modelo general

Los modelos entrenados con datos combinados (sin segmentar por grupo) alcanzaron niveles aceptables de desempeño, siendo el modelo con variables seleccionadas por PLS el más destacado ($R^2 = 0.939$, MAE = 1.631),

seguido del modelo con variables Lasso ($R^2 = 0.919$) y el modelo basado en variables expertas ($R^2 = 0.897$). Este hallazgo indica que, en contextos donde no es posible segmentar previamente los datos, la regresión PLS puede ofrecer una solución robusta y generalizable.

3) Análisis transversal de las técnicas de selección

- Lasso demostró ser especialmente efectiva en reducir la dimensionalidad y evitar el sobreajuste, especialmente en segmentos con mayor ruido o complejidad operativa (como Operadores).

- PLS, por su parte, resultó más eficaz en captar la estructura latente del sistema, lo que se tradujo en un mejor desempeño en grupos más estables como Receta y APC_Raman.

- La selección basada en conocimiento experto, si bien útil como punto de partida, mostró limitaciones al no adaptarse a la variabilidad específica de cada grupo.

En todos los casos, el grupo APC_Raman se destaca como el entorno más favorable para implementar sensores blandos, gracias a su estabilidad y riqueza de señales informativas.

XI. CONCLUSIONES

Este estudio evidencia que las redes neuronales multicapa (MLP), en combinación con técnicas avanzadas de selección de variables como Lasso y PLS, constituyen una herramienta poderosa para el diseño de sensores blandos en procesos de fermentación industrial. Estas arquitecturas son capaces de capturar con alta precisión la dinámica compleja de la producción de penicilina a partir de datos operacionales y fisicoquímicos recolectados en tiempo real.

La segmentación de los datos por estrategia de control operativo ya sea basada en recetas, decisiones de operadores o sistemas APC asistidos por espectroscopia Raman, resultó esencial para mejorar la capacidad predictiva de los modelos. Los resultados demostraron que los modelos entrenados específicamente para cada grupo superan en desempeño a aquellos construidos sobre datos combinados, lo cual resalta la importancia de una modelación contextualizada y orientada al entorno operativo.

Respecto a los métodos de selección de variables, PLS mostró un comportamiento más robusto en contextos estables como los segmentos Receta y APC_Raman, mientras que Lasso destacó en escenarios más variables y menos estructurados, como el control manual. Esta diferencia sugiere que la elección del enfoque de selección debe alinearse con el grado de estabilidad y complejidad del sistema bajo estudio.

La integración de espectroscopía Raman, a través de estrategias de control avanzado, permitió alcanzar los mayores niveles de precisión predictiva, consolidándola como una tecnología clave para el monitoreo inteligente de bioprocesos. No obstante, los modelos aplicados al grupo Fallas reflejaron un desempeño considerablemente inferior, lo que evidencia la necesidad de diseñar modelos especializados para la detección temprana y gestión de condiciones anómalas.

En síntesis, este trabajo valida el potencial del enfoque híbrido entre aprendizaje profundo y selección estadística de variables como base para el desarrollo de sensores blandos precisos, escalables e integrables en sistemas industriales reales de monitoreo y control en biotecnología.

ANEXOS

- Enlace de la presentación: https://proyectoretoinsulina-inrae-icesi.streamlit.app/
- Enlace del video: https://youtu.be/7MP82iCSn90?feature=shared

REFERENCIAS

[1] S. Goldrick et al., "Modern day monitoring and control challenges outlined on an industrial-scale benchmark fermentation process," *Computers & Chemical Engineering*, vol. 130, pp. 106471, 2019.

[2] S. Goldrick et al., "The development of an industrial-scale fed-batch fermentation simulation," *Journal of Biotechnology*, vol. 193, pp. 70–82, 2015.

[3] J. C. Acosta-Pavas et al., "Soft sensors based on interpretable learners for industrial-scale fed-batch fermentation: Learning from simulations," *Computers & Chemical Engineering*, vol. 187, pp. 108736, 2024.

[4] Assidjo, N. E., Akaki, D., Yao, B. K., & Eboi, T. Y. (2009). *A hybrid neural network approach for batch fermentation simulation*. *Australian Journal of Basic and Applied Sciences, 3*(4), 3930-3936.